

République Tunisienne
Ministère de l'Enseignement Supérieur
et de la Recherche Scientifique

Université de Sfax

L'Institut Supérieur d'Informatique
et de Multimédia de Sfax



Master de Recherche en :
Sciences de l'Informatique

Option :
Multimédia

N° d'ordre :

MEMOIRE

présenté à

**L'Institut Supérieur d'Informatique
et de Multimédia de Sfax**

en vue de l'obtention du

**Diplôme National de Master de Recherche en :
Sciences de l'Informatique**

**Option :
Multimédia**

par

Farah KHEMAKHEM

**Identification automatisée du *dinoflagellé toxique Karenia
Selliformis* à partir de la cytométrie en flux**

Soutenu le 20/12/2024 devant la commission d'examen :

M. Ismael BOUASSIDA
Mme. Salma BEN JEMAA
Mme. Raida KTARI

Président
Rapporteuse
Encadrante



Dédicaces

À ma chère mère,

Dont l'amour infini et la douceur m'ont offert des racines solides et des ailes pour m'élever. Tu es la lumière qui illumine mes journées, le soutien qui m'encourage à avancer et l'énergie qui m'insuffle la force au quotidien. Merci pour tout ton amour et pour tout ce que tu as fait pour moi.

À mon cher père,

Ta force, ta sagesse et ton amour inconditionnel m'ont toujours guidée à travers les défis de la vie. Tu m'as appris à persévérer, à croire en moi et à repousser mes limites. Merci pour ton appui indéfectible et tes conseils éclairés qui ont illuminé mon chemin.

À ma chère soeur,

Mon alliée, mon modèle, ma confidente. Ta générosité, ton courage et ta détermination m'inspirent chaque jour. Grâce à toi, j'ai appris qu'avec la volonté, tout est possible. Merci d'être toujours présente pour moi, avec ta force et ton soutien inlassables.

À mon cher frère,

Ton courage, ton sens de la justice et ta persévérance sont une source d'inspiration constante. Tu m'as montré que rien n'est impossible quand on y met tout son cœur. Merci pour ta présence rassurante et ton soutien fidèle.

À ma chère tata,

À chaque échange avec toi, je ressens une source infinie de réconfort et de force. Ta douceur, semblable à celle du miel, apaise mon cœur et ravive mon esprit. Je te suis profondément reconnaissante pour l'influence positive que tu as eue sur ma vie.

À ma personne préférée,

Toi qui as été à mes côtés à chaque étape de cette aventure, m'encourageant dans les moments de doute et me donnant la force d'aller au-delà de mes limites. Ta confiance et ton soutien ont rendu chaque défi plus facile. Je te remercie de tout cœur pour ton rôle inestimable dans cette réussite

À ma famille, à mes proches et à tous ceux qui m'ont apporté amour et énergie. Ce travail est dédié à chacun d'entre vous, qui avez joué un rôle essentiel dans ma réussite. Vous êtes des piliers dans ma vie et une source constante de motivation et d'inspiration.

À vous tous,

Je dédie ce travail.

Farah KHEMAKHEM



Remerciement

C'est avec un immense plaisir que je dédie ces lignes en signe de gratitude et de reconnaissance à toutes les personnes qui, de près ou de loin, ont contribué à l'élaboration de ce travail. Par leur soutien et leur engagement, chaque personne a joué un rôle essentiel dans la réussite de cette aventure, et je tiens à leur exprimer ma sincère gratitude.

Je remercie tout particulièrement Madame Raida KTARI, mon encadrante, pour son écoute attentive, sa patience et son engagement constant à mes côtés. Son accompagnement bienveillant, empreint d'une grande humanité, ainsi que ses conseils précieux, ont été essentiels tout au long de ce travail de mémoire. Elle a su allier rigueur scientifique et une gentillesse remarquable, créant un environnement de travail à la fois stimulant et bienveillant. Je lui suis profondément reconnaissante d'avoir partagé son expertise avec tant de générosité, m'orientant vers les meilleures pistes et restant toujours disponible pour répondre à mes questions.

Je souhaite également exprimer toute ma reconnaissance à Madame Yosr GHOZZI pour sa disponibilité constante et son soutien indéfectible. Sa bienveillance, sa gentillesse et sa grande humanité m'ont particulièrement touchée et motivée. Par son aide précieuse et son enthousiasme communicatif, elle a su me guider et m'encourager dans les moments de doute. Ses qualités humaines et professionnelles ont largement contribué à la réalisation de ce projet.

Grâce à Madame Raida et Madame Yosr, j'ai eu l'opportunité de découvrir le monde fascinant de la recherche scientifique. Leur passion et leur dévouement m'ont permis de m'immerger dans cet univers, éveillant en moi une curiosité scientifique qui n'a cessé de grandir. Leur influence a été décisive dans mon cheminement, me poussant à approfondir mes connaissances et à m'engager pleinement dans cette voie. Elles m'ont transmis un véritable amour pour la recherche, me permettant d'en saisir toute la richesse et l'importance.

Je tiens à exprimer ma profonde gratitude aux membres du laboratoire Milieu marin de l'INSTM pour leur soutien et leur collaboration tout au long de ce projet. Mes remerciements vont particulièrement à Madame Malika BELHASSEN, dont l'accueil exceptionnel, la bienveillance et le partage constant de son expertise ont été une source d'inspiration et d'enrichissement quotidien. Son accompagnement attentif et sa disponibilité inégalée ont profondément marqué le déroulement et la qualité de ce travail.

Je tiens également à exprimer ma reconnaissance à Madame Asma HAMZA, pour son expertise scientifique et son accompagnement généreux tout au long de ce travail, ainsi que pour son implication constante dans l'avancement du projet.

Mes remerciements sincères vont aussi à Madame Fatma ABDMOULEH, dont la disponibilité, la rigueur scientifique et son rôle clé dans la validation des données ont assuré une grande fiabilité et crédibilité aux résultats obtenus. J'adresse également mes remerciements à Madame Lamia DAMMAK pour son implication essentielle dans la validation des données.

Je tiens à remercier sincèrement Madame Yosra KHAMMERI et Monsieur Ismail BOUDRIGA pour leur collaboration précieuse et leur soutien constant tout au long de ce projet. Leur disponibilité et leur implication dans les échanges techniques ont été inestimables. Leur contribution a été essentielle et a enrichi cette expérience de manière significative.

Enfin, un grand merci à Madame Mabrouk MAHFOUDHI pour son expertise pratique et son aide précieuse dans la réalisation des expériences en laboratoire

Enfin, je remercie sincèrement les membres du jury pour l'honneur qu'ils me font en acceptant d'évaluer ce travail.

Que ce travail soit le modeste témoignage de ma plus haute considération et de mon profond respect envers toutes les personnes qui ont contribué à sa réalisation.

Du fond du cœur, Merci

Table des matières

Liste des figures	ix
Liste des abréviations	x
Introduction Générale	xi
1 Cadre et contexte généraux	2
1.1 Introduction	3
1.2 Cadre général	3
1.2.1 Présentation de l'organisme d'accueil	3
1.2.2 Missions de l'INSTM	4
1.2.3 Étude du projet	4
1.2.4 Étude de l'existant	5
1.2.5 Problématique	7
1.2.6 Objectifs	7
1.2.7 Solution proposée	7
1.3 Contexte général	8
1.3.1 <i>Karenia selliformis</i>	8
1.3.1.1 Description morphologique	9
1.3.1.2 Facteurs environnementaux favorisant la prolifération	10
1.3.1.3 Conséquences du <i>K.Selliformis</i> sur l'écosystème marin	10
1.3.1.4 <i>K.Selliformis en Tunisie</i>	12
1.3.2 Cytométrie en flux	13
1.3.2.1 Principes Techniques de la cytométrie en flux	13
1.3.2.2 Applications de la cytométrie en flux	15
1.3.2.3 Avantages et inconvénients de la cytométrie en flux	16
1.4 Méthodologie de travail	17
1.4.1 Etapes de la méthodologie CRISP-DM	18
1.4.2 Intégration des principes agile	20

1.5	Conclusion	21
2	État de l'art et présentation des techniques utilisées	22
2.1	Introduction	23
2.2	Intelligence artificielle	23
2.2.1	Apprentissage automatique	24
2.2.2	Apprentissage profond	24
2.2.3	Réseau de neurones convolutifs	25
2.2.4	Architecture de CNN particulières	27
2.3	Revue de la littérature scientifique	30
2.4	Synthèse	40
2.5	Conclusion	43
3	Methodologie et développement du modèle	44
3.1	Introduction	45
3.2	Architecture globale du projet	45
3.3	Collecte de données	46
3.4	Préparation de données	47
3.4.1	Nettoyage de données	47
3.4.2	Annotation de données	48
3.5	Détection et extraction des cellules	53
3.5.1	Entraînement du modèle	53
3.5.2	Détection des microalgues avec YOLOv8	55
3.5.3	Extraction de boîtes englobantes	56
3.6	Classification des microalgues	57
3.6.1	Apprentissage par transfert	57
3.6.2	Modèles préentraînés/Architecture utilisée	58
3.6.3	Entraînement des modèles	60
3.7	Conclusion	61
4	Résultats expérimentaux et synthèse	62
4.1	Introduction	63
4.2	Environnement matériel et logiciel	63
4.2.1	Environnement matériel	63
4.2.2	Environnement logiciel	64
4.3	Mesures d'évaluation	66
4.4	Résultats expérimentaux	69

4.4.1	Résultats du modèle de détection (YOLOv8)	69
4.4.1.1	Ajustements des paramètres pour la détection	69
4.4.1.2	Évaluation des performances et sélection du modèle optimal .	70
4.4.2	Résultats des modèles de classification	72
4.4.2.1	Ajustements des paramètres pour la classification	72
4.4.2.2	Comparaison des modèles sur l'ensemble du test	74
4.4.3	Evaluation des résultats	77
4.5	Synthèse de l'Approche	78
4.6	Transition vers l'intégration des modèles	79
4.6.1	Présentation de l'application web	79
4.6.2	Aspects techniques	79
4.6.2.1	Backend : API Flask pour la détection et la classification . .	80
4.6.2.2	Frontend : Automatisation des calculs et gestion visuelle avec Streamlit	81
4.6.3	Interface utilisateur et fonctionnalités	82
4.6.3.1	Interface de chargement et de détection des images	82
4.6.3.2	Affichage des résultats de la détection et de la classification .	83
4.7	Conclusion	85
CONCLUSION GÉNÉRALE		86
BIBLIOGRAPHIE		88

Liste des figures

1.1	Logo de l'INSTM	3
1.2	Procédure de détection du <i>Selliformis</i> par microscope	5
1.3	Classification des cellules par la cytométrie en flux	6
1.4	Images de <i>Karenia selliformis</i>	8
1.5	Description morphologique du <i>Karenia selliformis</i>	9
1.6	Les Conséquences du <i>K.Selliformis</i> [4]	10
1.7	Le cytomètre	13
1.8	Principes Techniques de la cytométrie en flux	13
1.9	système Fluidique	14
1.10	système optique	14
1.11	Diagramme du processus CRISP-DM	18
2.1	Schéma des relations entre l'intelligence artificielle, l'apprentissage automatique et l'apprentissage profond [10]	24
2.2	Réseau de neurones convolutif [14]	26
2.3	La technique de Dropout [15]	27
3.1	Architecture globale de la méthodologie	45
3.2	Le logiciel CytoClus	46
3.3	Échantillon des images constituant la base de données	47
3.4	Les classes annotées avec RoboFlow	49
3.5	Exemple du <i>K.Selliformis</i> annoté avec Roboflow	50
3.6	Exemple d'autres cellules annotées avec Roboflow	51
3.7	Technique de redimensionnement	52
3.8	Technique de Division	52
3.9	Les types d'exportation des données	53
3.10	Les tailles de Yolov8	55
3.11	Entraînement du modèle	55
3.12	Exemple de détection de cellules	56
3.13	Exemple de cellules extraits	57

3.14	Structure des modèles pour l'apprentissage par transfert	60
4.1	Logo de Roboflow	64
4.2	Logo de Google Colab	64
4.3	Logo de Python	65
4.4	Logo de TensorFlow	65
4.5	Logo de Numpy	66
4.6	Logo de PyTorch	66
4.7	Matrice de confusion générale [47]	67
4.8	Illustration de l'IOU à différents seuils [48]	68
4.9	Matrice de confusion pour YOLOv8	71
4.10	Courbes de Perte d'Entraînement et de Validation	75
4.11	Courbes d'accuracy d'entraînement et de validation	75
4.12	Résultat du modèle ResNet50	76
4.13	Classification des images par ResNet50	77
4.14	Résultats de classification	78
4.15	API Flask	81
4.16	Interface de chargement des données	82
4.17	Résultats de la détection pour les autres microalgues	83
4.18	Résultats de la détection pour le <i>Karenia Selliformis</i>	83
4.19	Extraction des autres microalgues	84
4.20	Extraction du <i>Karenia Selliformis</i>	84
4.21	Rapport global	85



Liste des abréviations

K.Selliformis Karenia Selliformis

IA Intelligence Artificielle

IFC Cytométrie en Flux d’Imagerie

CMF Cytométrie en flux

CNN Convolutional Neural Network

CRISP-DM Cross Industry Standard Process for Data Mining

YOLO You Only Look Once

mAP mean Average Precision



Introduction Générale

L'intelligence artificielle (IA) est une technologie transformative qui révolutionne divers secteurs, de la santé à la finance, en passant par les transports et l'industrie manufacturière. En analysant de vastes quantités de données, optimisant des processus complexes, et automatisant des tâches répétitives, l'IA permet des gains significatifs en efficacité et en précision. Une branche de l'IA, le deep learning, se distingue par sa capacité à apprendre et extraire des informations pertinentes à partir de données brutes grâce à des réseaux de neurones artificiels sophistiqués.

Le deep learning a trouvé des applications remarquables dans la reconnaissance d'images, la compréhension du langage naturel, et la prédiction de tendances, entre autres. Dans le domaine de la santé, par exemple, il est utilisé pour diagnostiquer des maladies à partir d'images médicales avec une précision souvent supérieure à celle des experts humains. En finance, il aide à détecter les fraudes et à prévoir les mouvements de marché. Les véhicules autonomes bénéficient également du deep learning, qui leur permet de naviguer de manière sûre et efficace.

En biologie et en écologie, l'IA et le deep learning ouvrent de nouvelles perspectives pour surveiller et protéger les écosystèmes naturels. Une application particulièrement prometteuse est la reconnaissance automatique des microalgues toxiques, qui représentent une menace importante pour les écosystèmes marins et la santé publique. Les microalgues comme *Karenia selliformis* produisent des toxines pouvant nuire à la vie marine, aux activités de pêche, et à la santé humaine.

La prolifération de *Karenia Selliformis* dans les eaux marines peut perturber les équilibres écologiques et économiques. Les marées rouges causées par ces microalgues peuvent dégrader la qualité de l'eau, affecter la biodiversité et entraîner des pertes économiques pour les industries

de la pêche et du tourisme. Ainsi, la surveillance et la gestion de ces microalgues toxiques sont cruciales pour préserver les écosystèmes marins et protéger les communautés humaines.

Traditionnellement, la reconnaissance de *K. Selliformis* était réalisée manuellement par des experts, un processus long et sujet à des erreurs humaines. Cependant, l'avènement de la cytométrie en flux d'imagerie (IFC) combinée au deep learning offre de nouvelles possibilités pour automatiser et améliorer cette tâche. La cytométrie en flux d'imagerie capture des images détaillées des cellules en suspension, et les algorithmes de deep learning peuvent être entraînés pour reconnaître automatiquement les caractéristiques spécifiques de *K. selliformis*.

En utilisant des réseaux de neurones convolutifs (CNN) et d'autres techniques de deep learning, il est possible de développer des modèles capables d'analyser rapidement et avec précision les images obtenues par IFC, réduisant ainsi le temps et les efforts nécessaires pour la classification des microalgues toxiques. Cette approche permet non seulement d'accélérer le processus de reconnaissance, mais aussi d'améliorer la précision et la fiabilité des analyses.

Ce mémoire explore l'application du deep learning pour la classification automatique de *K. selliformis* à partir des images capturées par cytométrie en flux d'imagerie. Il met en lumière l'importance cruciale de la protection de l'environnement marin contre les menaces posées par les microalgues toxiques et examine les conséquences écologiques et socio-économiques de leur prolifération. En proposant des solutions technologiques avancées pour une surveillance et une gestion améliorées des écosystèmes marins, ce travail vise à contribuer de manière significative à la préservation de nos océans. Pour cette fin, ce travail sera alors réparti en quatre chapitres :

Dans le premier chapitre, nous introduisons l'organisme d'accueil et définissons le cadre du projet. Nous y effectuons une étude de l'existant pour identifier les principales problématiques rencontrées et présenter la solution que nous proposons pour y remédier . Ce chapitre inclut également une description détaillée de la méthodologie adoptée tout au long du projet, ainsi qu'une présentation des concepts fondamentaux de biologie nécessaires à la compréhension de notre démarche.

Dans le deuxième chapitre, nous abordons les fondements théoriques de l'intelligence artificielle, en se focalisant sur les architectures de réseaux de neurones profonds, essentiels

pour la détection et la classification d'images. Nous explorons les concepts clés, les différentes architectures de réseaux neuronaux, et les algorithmes de deep learning utilisés dans ce domaine. Ensuite, nous présenterons les différentes études qui ont déjà abordé les méthodes de classification des microalgues, en détaillant les approches actuelles, les performances obtenues, et les limites rencontrées. Enfin, ce chapitre se termine par une synthèse qui rend compte des points forts et des limites de ces différentes approches.

Le troisième chapitre sera consacré à la description détaillée de l'architecture de notre approche pour la classification de *Karenia selliformis*. Ce chapitre couvrira les étapes de préparation des données, les paramètres de configuration du modèle.

Le quatrième chapitre est dédié à la présentation des environnements de travail et des outils utilisés, ainsi qu'à l'évaluation des résultats obtenus. Nous y détaillerons les configurations matérielles et logicielles mises en place pour mener nos expérimentations. Ensuite, nous discuterons des performances des modèles testés en mettant en évidence les résultats clés, avec une analyse comparative des différentes approches utilisées.

Cadre et contexte généraux

Sommaire

1.1	Introduction	3
1.2	Cadre général	3
1.2.1	Présentation de l'organisme d'accueil	3
1.2.2	Missions de l'INSTM	4
1.2.3	Étude du projet	4
1.2.4	Étude de l'existant	5
1.2.5	Problématique	7
1.2.6	Objectifs	7
1.2.7	Solution proposée	7
1.3	Contexte général	8
1.3.1	<i>Karenia selliformis</i>	8
1.3.2	Cytométrie en flux	13
1.4	Méthodologie de travail	17
1.4.1	Étapes de la méthodologie CRISP-DM	18
1.4.2	Intégration des principes agile	20
1.5	Conclusion	21

1.1 Introduction

Ce chapitre introductif pose le cadre général de notre projet, constituant ainsi une base essentielle pour son développement. Il débute par une revue de l'existant, permettant d'identifier les besoins spécifiques et les défis techniques à relever. Cette analyse fournit une orientation claire pour définir les objectifs précis nécessaires à la conception et à la mise en œuvre d'une solution adaptée et performante. Par la suite, une méthodologie détaillée sera exposée, structurant de manière qui se veut rigoureuse les étapes de développement. Enfin, on abordera les concepts biologiques et technologiques fondamentaux indispensables à la compréhension de ce projet afin d'avoir une vision complète et cohérente des enjeux de cette expérience scientifique.

1.2 Cadre général

1.2.1 Présentation de l'organisme d'accueil

L'Institut National des Sciences et Technologies de la Mer (INSTM) est un établissement public en Tunisie spécialisé dans les domaines des sciences marines et des technologies liées à la mer. Créé en 1924, il est sous la tutelle du ministère de l'Agriculture, des Ressources Hydrauliques et de la Pêche. L'INSTM est l'un des principaux centres de recherche en océanographie et en aquaculture dans le pays. Il dispose de plusieurs centres à Carthage Salammbô, Kheireddine, La Goulette, Sfax, Mahdia, Gabes, Zarzis, Tabarka, et Monastir, ce qui lui permet d'étendre ses activités de recherche sur le territoire.



FIGURE 1.1 – Logo de l'INSTM

1.2.2 Missions de l'INSTM

Voici les différentes activités assurées par cet institut :

- Mener des programmes de recherche dans des domaines liés directement ou indirectement à la mer et à ses ressources : pêche, agriculture, environnement marin, technologies de la mer, océanographie, etc.
- Participer aux réseaux nationaux, régionaux et internationaux en lien avec les enjeux maritimes.
- Partager les résultats de ses recherches avec les décideurs, les professionnels de la mer et les scientifiques.
- Agir comme outil d'aide à la décision pour garantir une gestion durable des ressources marines.
- Sensibiliser le public à la protection et à la préservation de la mer et de sa biodiversité.
- Encadrer les étudiants en doctorat, en master, et lors de projets de fin d'études, et les préparer à la vie professionnelle.
- Réaliser des études spécifiques pour les investisseurs et fournir des informations techniques.
- Effectuer des analyses de laboratoire dans ses spécialités, en partenariat avec les réseaux nationaux.
- Organiser des manifestations scientifiques et techniques pour publier, valoriser et évaluer les résultats des recherches.

1.2.3 Étude du projet

Ce projet s'inscrit dans le cadre d'une convention de collaboration entre l'Institut National des Sciences et Technologies de la Mer et l'université de Sfax. L'objectif de ce projet est de permettre aux biologistes d'optimiser la précision et la rapidité de la détection et de la classification de la microalgue toxique *Karenia Selliformis*.

1.2.4 Étude de l'existant

La détection de *Karenia Selliformis* en Tunisie met en avant les méthodes manuelles actuellement utilisées dans la plupart des laboratoires de l'INSTM, qui commencent par la réception des échantillons d'eau de mer. Ceux-ci sont fixés dans des cuves de sédimentation contenant un liquide de conservation, le lugol, puis doivent reposer pendant environ 8 heures pour stabiliser les cellules. Avant l'analyse microscopique, divers paramètres physicochimiques, tels que la salinité, la température et le pH, sont mesurés pour fournir un contexte environnemental. Lors de l'examen microscopique, les biologistes détectent la présence des microalgues en balayant l'ensemble de la cuve, en se focalisant sur chaque cellule pour l'identifier et déterminer si elle est toxique.

La figure suivante illustre le déroulement de notre expérience au laboratoire de l'INSTM, où nous avons eu le plaisir de vivre de près la procédure de détection de *Karenia Selliformis*, telle que réalisée par les biologistes.



1 étapes: réception des échantillons



2 étapes: fixation des prélèvements



3 étapes: Mesure des paramètres physico-chimiques



4 étapes: observation par microscope et comptage des cellules

FIGURE 1.2 – Procédure de détection du .Selliformis par microscope

La deuxième méthode de détection de *Karenia Selliformis*, la plus avancée, repose sur l'utilisation de cytomètres en flux. Ce dispositif mobile est placé à bord d'un bateau et équipé de tuyaux pour prélever des échantillons directement de la mer. À l'intérieur, plusieurs systèmes sont conçus pour capturer des images de toutes les cellules présentes dans les échantillons. Les images ainsi obtenues sont ensuite enregistrées par le système informatique dans un logiciel dédié, tel que CytoClus. Ce dernier permet la classification des microalgues en fonction de leur structure, ce qui améliore considérablement l'efficacité du processus initial. Cependant, malgré ces avancées, la classification au niveau des espèces reste limitée, car de nombreuses cellules présentent une structure similaire. Il est souvent nécessaire que des experts interviennent pour classer et identifier manuellement et reclasser les cellules, notamment pour distinguer les microalgues toxiques comme *Karenia selliformis*.

La figure suivante illustre la classification uniquement selon la structure des cellules, réalisée par la cytométrie en flux d'imagerie.




FIGURE 1.3 – Classification des cellules par la cytométrie en flux

1.2.5 Problématique

Le temps consacré à l'examen des échantillons est considérable, ce qui entraîne des retards significatifs dans l'obtention des résultats. Cette perte de temps s'avère cruciale dans un contexte où la réactivité est indispensable pour gérer les risques liés aux blooms de microalgues.

Le risque d'erreur dans l'identification de cet organisme est élevé, car la morphologie de plusieurs cellules est similaire et peut entraîner par conséquent des confusions.

Ces erreurs peuvent avoir des conséquences graves sur l'écosystème, notamment en facilitant la prolifération de microalgues toxiques qui nuisent à la biodiversité marine, perturbant ainsi les chaînes alimentaires et affectant la qualité de l'eau.

1.2.6 Objectifs

Ce projet vise à outrepasser les limitations actuelles de la détection de *Karenia selliformis* en Tunisie en développant une solution novatrice fondée sur l'intelligence artificielle pour :

- Automatiser la détection et la classification de *Karenia selliformis*, une micro-algue toxique, en utilisant des techniques d'intelligence artificielle pour améliorer la surveillance des écosystèmes marins.
- Optimiser la précision et la rapidité des processus de détection pour minimiser la dépendance aux méthodes manuelles et réduire les risques d'erreurs.
- Faciliter l'accès à une réponse rapide face aux blooms de *Karenia selliformis*, en réduisant le temps d'analyse et en protégeant les écosystèmes contre les impacts environnementaux négatifs.

1.2.7 Solution proposée

Pour combler les lacunes des méthodes actuelles, nous proposons une solution combinant l'intelligence artificielle et les données issues de la cytométrie en flux d'imagerie, afin d'automatiser la détection et la classification de la micro-algue toxique *Karenia selliformis*.

1.3 Contexte général

1.3.1 *Karenia selliformis*

"*Karenia selliformis* est une espèce de *Karenia*, appartenant à la catégorie des dinoflagellés. Découverte pour la première fois en Nouvelle-Zélande. Cette espèce est connue pour produire de la *gymnodimine*, une phycotoxine hautement toxique qui bloque les récepteurs nicotiniques de l'acétylcholine, représentant ainsi un danger potentiel pour les habitants de l'océan." [1] La figure suivante présente des images de *Karenia selliformis* capturées sous différents angles.




FIGURE 1.4 – Images de *Karenia selliformis*

1.3.1.1 Description morphologique




FIGURE 1.5 – Description morphologique du *Karenia selliformis*

Karenia selliformis se distingue par une morphologie unique qui lui permet de se classer au sein de la famille des Kareniaceae. Ses cellules, généralement de forme discoïde et aplaties dans le sens dorso-ventral, varient en taille, mesurant entre 35,3 et 43,6 μm de longueur (avec une moyenne de $39,4 \pm 2,1 \mu\text{m}$) et entre 31,8 et 44,7 μm de largeur (moyenne de $37,3 \pm 3,2 \mu\text{m}$). En culture, ces cellules tendent à adopter une forme légèrement ellipsoïdale, avec des dimensions allant de 38,6 à 48,8 μm de longueur (moyenne de $43,0 \pm 2,6 \mu\text{m}$) et de 30,9 à 40,1 μm de largeur (moyenne de $36,3 \pm 2,5 \mu\text{m}$).

L'épicône a une forme conique et arrondie, comparable en taille à l'hypocône hémisphérique, avec une dépression antapicale visible. La face ventrale des cellules est lisse et plate, alors que le côté dorsal présente une convexité et des rides, agrémentées de striations longitudinales. Le cingulum entoure la cellule au niveau médian, s'abaissant d'une à trois fois sa propre largeur. Le sillon, profond, s'étend jusqu'à la dépression antapicale et possède une courte extension antérieure, large et ouverte. Les chloroplastes, nombreux, prennent une forme granulaire ou en bande, avec des courbures irrégulières et un pyrénoïde interne, se situant à la périphérie de la cellule. Le noyau, de forme allongée, est situé dans l'hypocône, avec une partie gauche légèrement plus développée s'étendant vers l'avant. De plus, deux pusules

sont positionnées près des canaux flagellaires longitudinal et transversal, et il est possible d'observer des sécrétions de matériaux translucides de forme irrégulière ainsi que l'éjection de trichocystes.[2]

1.3.1.2 Facteurs environnementaux favorisant la prolifération

Karenia selliformis se développe particulièrement bien dans certaines conditions environnementales. Les facteurs les plus propices à sa prolifération incluent une salinité élevée, une pression atmosphérique accrue et des marées réduites. Ces éléments créent un milieu favorable à sa croissance.[3] De plus, cette espèce tend à apparaître fréquemment durant l'automne, une période qui coïncide avec des changements climatiques susceptibles d'affecter la température et les cycles d'eau, favorisant ainsi les conditions nécessaires à la formation de blooms algaux. Par ailleurs, la prolifération de *Karenia selliformis* s'intensifie en présence de chaleur, combinée à la lumière et à la pollution, ce qui augmente les risques liés à cette espèce.[4]

1.3.1.3 Conséquences du *K.Selliformis* sur l'écosystème marin



FIGURE 1.6 – Les Conséquences du *K.Selliformis* [4]

Comme illustré dans la figure 1.6, les blooms de *Karenia selliformis* entraînent des conséquences significatives et préoccupantes pour l'écosystème marin. L'une des menaces les plus graves provient de la production de toxines, qui peuvent causer une mortalité massive chez les poissons. Lors de ces blooms, les concentrations élevées de toxines peuvent interférer avec le système nerveux des poissons, entraînant des symptômes allant de la désorientation à la mort. Cela affecte non seulement les populations de poissons, mais perturbe également les chaînes alimentaires marines. La mortalité des poissons a des implications directes sur les écosystèmes aquatiques, provoquant un déséquilibre qui peut affecter d'autres espèces, y compris les prédateurs marins qui dépendent de ces poissons pour leur survie.

Les effets de *K. Selliformis* ne se limitent pas à la faune : ils touchent aussi les fruits de mer, Produit de la substance toxique qui peut s'accumuler dans les tissus des fruits de mer notamment les coquillages (moules, huîtres, palourdes, etc) qui filtrent l'eau pour se nourrir. La consommation de ces coquillages contaminés peut représenter un danger pour la santé humaine, entraînant des intoxications alimentaires sévères

Un autre aspect préoccupant des blooms de *Karenia* est leur association avec les marées rouges. Ces événements, marqués par des concentrations élevées de dinoflagellés, ne se contentent pas de créer des impacts visuels spectaculaires, mais engendrent également des effets écologiques néfastes. La présence excessive de *Karenia selliformis* dans les eaux côtières peut réduire la quantité de lumière pénétrant dans l'eau, ce qui nuit à la photosynthèse des algues et du phytoplancton, des organismes essentiels pour le maintien de la chaîne alimentaire marine. Ce phénomène peut entraîner une diminution de la biodiversité dans les écosystèmes marins, affectant à la fois les organismes benthiques et pélagiques.

En outre, les marées rouges peuvent avoir des répercussions économiques considérables. Les fermetures des zones de pêche et des plages pour des raisons de sécurité sanitaire peuvent causer des pertes financières pour les communautés côtières qui dépendent de la pêche et du tourisme. Les effets cumulatifs des blooms de cet mirco-algues peuvent donc être dévastateurs non seulement pour l'environnement, mais aussi pour les économies locales et le bien-être des populations humaines.

1.3.1.4 *K.Selliformis en Tunisie*

Les côtes tunisiennes, avec leur grande diversité d'écosystèmes marins, sont souvent touchées par divers phénomènes naturels et anthropiques, notamment les efflorescences algales. Parmi ces phénomènes, le golfe de Gabès, situé au sud de la Tunisie, est particulièrement affecté par les blooms de dinoflagellés toxiques

Karenia selliformis est l'une des espèces les plus préoccupantes dans cette région, étant responsable de 64% à 70% des efflorescences toxiques observées. Présente dans le sud de la Tunisie depuis les années 1990, elle fut initialement signalée sous les noms de *Gyrodinium aureolum* et *Gymnodinium selliforme*. C'est en 1994 qu'un épisode notable a été enregistré : une coloration rougeâtre de l'eau a été détectée, provoquée par une concentration exceptionnellement élevée de *Gymnodinium sp*, estimée à 60 millions de cellules par litre. Cet événement a conduit à la mort massive de poissons, estimée à environ 200 tonnes. Ce n'est qu'en 2004 que l'espèce a été identifiée correctement comme *Karenia selliformis*, marquant ainsi un tournant dans la surveillance des écosystèmes marins tunisiens.

Les conséquences des efflorescences toxiques de *Karenia selliformis* dans le golfe de Gabès ont eu un impact significatif sur l'économie locale, notamment sur la production de palourdes (*Ruditapes decussatus*). En 1995, cette production atteignait 1500 tonnes, dont 1200 tonnes étaient destinées à l'exportation, générant un revenu estimé à 7 millions d'euros par an et soutenant environ 6000 personnes. Cependant, au cours des dernières années, la quantité de palourdes exportées a chuté à 400-600 tonnes par an, en raison de la présence récurrente de *Karenia selliformis* dans le golfe. L'année 1994 a été marquée par des mortalités massives d'organismes marins (1 à 2 tonnes), incluant des anguilles, seiches, labridés, muges et sparidés, observées sur plusieurs côtes du golfe de Gabès.[5]

Depuis lors, ces proliférations toxiques sont devenues plus fréquentes et se sont étendues à plusieurs sites, notamment la lagune de Boughrara et d'autres zones côtières abritées. Ces événements perturbent gravement les écosystèmes locaux et menacent la viabilité économique de la pêche dans la région.[6]

1.3.2 Cytométrie en flux

La cytométrie en flux est une technique utilisée pour analyser les microalgues en suspension dans un échantillon environnemental. Elle permet d'obtenir une analyse rapide et précise en extrayant plusieurs caractéristiques d'une seule cellule tout en séparant les microalgues des autres particules indésirables, facilitant ainsi une analyse ultérieure approfondie. Cette méthode repose sur l'intégration de plusieurs systèmes clés : fluïdique, optique, électronique et informatique, qui collaborent pour assurer à la fois la séparation des microalgues et l'extraction des données pertinentes.[7]

La figure suivante présente une illustration de la cytométrie en flux.



FIGURE 1.7 – Le cytomètre

1.3.2.1 Principes Techniques de la cytométrie en flux




FIGURE 1.8 – Principes Techniques de la cytométrie en flux

La figure 1.8 illustre les principes techniques de la cytométrie en flux, qui repose sur l'interaction et l'intégration de quatre systèmes principaux : le système fluide, le système optique, le système électronique et le système informatique.

Système Fluidique

Le système fluide en cytométrie en flux joue un rôle essentiel pour assurer une manipulation précise des échantillons cellulaires. Le processus débute par l'introduction des cellules via une aiguille de précision, permettant une collecte minutieuse de l'échantillon. En parallèle, un liquide de gaine est injecté à l'aide d'une seringue de plus grand volume, créant un flux laminaire autour de l'échantillon. Ce flux guide les cellules en suspension, généralement de taille inférieure à 100 µm, en les alignant de manière ordonnée, comme dans une "file indienne". Cela garantit que chaque cellule passe individuellement au niveau du laser pour une analyse fiable et une extraction de données précises.[7]




FIGURE 1.9 – système Fluidique

Système Optique

Source de lumière

Lasers: Ions d'Argon, ion Krypton, HeNe, HeCd,

blue solid state laser 250 mW	488 nm	GREEN SHARP RED RED INFRARED	RED PE-Cy5 PE-Cy5	RED PE-Cy5 PE-Cy5	ALPHA FLUOR 488 PE-Cy5 PE-Cy5	STYL 488 PE-Cy5 PE-Cy5
red diode laser 25 mW	635 nm	RED INFRARED	RED APC-Cy7	RED APC-Cy7	ALPHA FLUOR 635 APC-Cy7	ALPHA FLUOR 635 APC-Cy7
green solid state laser 100 mW	532 nm	RED INFRARED	RED PE-Cy5	RED PE-Cy5	ALPHA FLUOR 532 PE-Cy5	ALPHA FLUOR 532 PE-Cy5
violet diode laser 50 mW	405 nm	ALPHA FLUOR 405	ALPHA FLUOR 405	ALPHA FLUOR 405	ALPHA FLUOR 405	ALPHA FLUOR 405
UV diode Laser 8 mW	375 nm	DAPI SYTOX	DAPI SYTOX	DAPI SYTOX	DAPI SYTOX	DAPI SYTOX

Lampes à vapeur: Mercure, Xénon, Mercure-Xénon |

FIGURE 1.10 – système optique

Le système optique de la cytométrie en flux est un élément clé, chargé de la détection et de l'analyse des cellules en suspension. Il se compose d'un faisceau laser qui illumine les cellules via un ensemble de lentilles, filtres, et miroirs dichroïques. Lorsque les cellules traversent le faisceau laser, elles émettent des signaux de diffusion et de fluorescence. Ces signaux sont ensuite captés et amplifiés par des photomultiplicateurs, convertis en signaux électriques, puis traités par un système électronique. Cela permet d'obtenir des données précises sur les caractéristiques physiques et biologiques des cellules, comme leur taille, complexité, fluorescence et l'expression de marqueurs spécifiques.[8]

Système Electronique

Le système électronique de la cytométrie en flux joue un rôle essentiel en convertissant les signaux optiques, sous forme de photons, en signaux électroniques mesurables, exprimés en volts. Ces signaux lumineux sont captés par des photomultiplicateurs, qui les amplifient et les convertissent en données numériques. Ces données sont ensuite traitées, numérisées, puis stockées dans un ordinateur pour analyse ultérieure, permettant ainsi d'obtenir des informations détaillées sur les caractéristiques des cellules étudiées.[8]

Système Informatique

Le système informatique permet de visualiser et d'interpréter les signaux générés lors de l'analyse. Il traite les données collectées, les transformant en graphiques et visualisations exploitables, facilitant ainsi l'interprétation des caractéristiques des cellules et la prise de décisions scientifiques.[8]

1.3.2.2 Applications de la cytométrie en flux

L'hématologie a été l'une des premières disciplines médicales à tirer parti des applications cliniques de la cytométrie en flux (CMF). Aujourd'hui, certaines de ces applications sont couramment utilisées pour diagnostiquer ou suivre l'évolution de diverses maladies, notamment les hémopathies malignes. La CMF permet non seulement l'étude fonctionnelle des cellules saines, mais aussi l'identification de leur caractère pathologique. Bien que les analyses ciblent

principalement les leucocytes, la CMF peut également affiner le diagnostic de certaines affections plaquettaires (comme les thrombopathies) ou des globules rouges.

En cancérologie, la CMF excelle dans la détection des cellules tumorales, notamment en mesurant des anomalies du contenu en ADN des noyaux cellulaires.

L'immunologie utilise également la CMF pour identifier et quantifier les sous-types cellulaires impliqués dans les réponses immunitaires.

Pour l'analyse du cycle cellulaire, la CMF offre une approche rapide et simple, permettant de suivre la répartition des cellules dans les différentes phases du cycle en fonction de stimuli spécifiques ou de l'ajout de médicaments. Elle permet aussi de détecter des cellules présentant des anomalies dans leur contenu en ADN.

En pharmacologie, la CMF est utilisée pour l'étude de nouvelles thérapies, comme les drogues antimitotiques ou les traitements immunothérapeutiques.

Dans le domaine de l'océanologie, la CMF est devenue une méthode standard pour compter les populations de picoplancton photosynthétique, en se basant sur la fluorescence des pigments comme la chlorophylle.[9]

1.3.2.3 Avantages et inconvénients de la cytométrie en flux

La cytométrie en flux offre plusieurs avantages significatifs pour la détection des microalgues.

- Analyse rapide et en temps réel : La cytométrie en flux permet de traiter et d'analyser un grand nombre de cellules en quelques secondes, ce qui est idéal pour les études de suivi et de surveillance en temps réel.
- Quantification précise : La méthode permet d'obtenir une quantification précise des cellules dans un échantillon, ce qui est essentiel pour les études de concentration de microalgues dans des milieux aquatiques
- Caractérisation multifactorielle : Grâce à l'utilisation de différents types de marqueurs fluorescents et de la lumière, il est possible de mesurer plusieurs paramètres

simultanément (taille, structure, fluorescence naturelle), permettant une classification approfondie des microalgues.

- **Préservation des échantillons** : La cytométrie en flux est généralement non destructive, ce qui signifie que les cellules peuvent rester intactes pour des analyses ultérieures.
- **Automatisation et reproductibilité** : La cytométrie en flux peut être automatisée, ce qui assure une standardisation des analyses et une reproductibilité élevée des résultats.

Malgré ses nombreux avantages, la cytométrie en flux présente certaines limitations pour la détection des microalgues

- **Limites dans la classification spécifique** : La cytométrie peut avoir des difficultés à distinguer des espèces de microalgues ayant des caractéristiques structurelles et optiques très similaires, limitant ainsi sa précision dans l'identification d'espèces spécifiques.
- **Coût élevé** : Les appareils de cytométrie en flux et leurs consommables sont coûteux, ce qui peut limiter leur utilisation pour les études à grande échelle ou dans des laboratoires aux ressources limitées.
- **Formation spécialisée requise** : La manipulation et l'interprétation des données de cytométrie en flux nécessitent une formation spécialisée, ce qui peut être un obstacle pour les équipes non expérimentées.

1.4 Méthodologie de travail

La méthodologie de travail constitue un pilier essentiel dans la gestion d'un projet, car elle offre une structure systématique pour atteindre les objectifs établis. En définissant clairement les étapes à suivre, elle permet non seulement une exécution efficace des tâches, mais aussi une planification rigoureuse. La gestion de projet va au-delà de l'exécution, elle exige une supervision continue et une évaluation approfondie à chaque phase. Cette approche garantit que chaque étape est réalisée conformément aux normes requises et que les résultats finaux s'alignent sur les attentes initiales.

Dans le cadre de ce projet, l'adoption d'une méthodologie structurée a été cruciale pour gérer efficacement les différentes étapes, depuis la collecte des données jusqu'à la validation

finale des résultats par des experts. Nous avons choisi une approche hybride qui combine les principes des méthodologies CRISP-DM et Agile. La méthodologie CRISP-DM (Cross Industry Standard Process for Data Mining), largement reconnue dans le domaine de la science des données, se compose de plusieurs phases clés qui facilitent une gestion itérative des données et des analyses. Cela nous a permis d'adopter une démarche rigoureuse et ordonnée, tout en maintenant une flexibilité nécessaire grâce à l'approche Agile, qui nous a permis d'intégrer des ajustements en temps réel, tels que l'incorporation de nouvelles données et les retours des biologistes experts. Cette synergie entre rigueur et adaptabilité a grandement contribué à l'efficacité de notre projet.

1.4.1 Etapes de la méthodologie CRISP-DM

Cette méthodologie a organisé le projet en six étapes essentielles, chacune contribuant de manière décisive à l'atteinte des objectifs fixés. La figure ci-dessous illustre ces étapes de façon visuelle, offrant une vue d'ensemble claire du processus CRISP-DM.




FIGURE 1.11 – Diagramme du processus CRISP-DM

1. Compréhension des objectifs métiers : La première phase a impliqué une analyse approfondie des besoins et des objectifs du projet, réalisée en étroite collaboration avec

les experts biologistes. L'objectif était de bien saisir leurs attentes spécifiques en ce qui concerne la détection et la classification de *Karenia selliformis*.

2. Compréhension des données : dans cette étape nous avons collecté les images de microalgues et effectué une première exploration des données. Cette phase nous a permis d'identifier les caractéristiques clés des images, notamment de distinguer *Karenia selliformis* des autres cellules. Elle a également servi à évaluer la qualité des données et à repérer d'éventuelles anomalies ou incohérences, nécessitant un nettoyage avant l'étape d'annotation.
3. Préparation des données : Ce processus a inclus l'annotation manuelle des microalgues, en les classant en deux catégories distinctes : *Karenia selliformis* et autres cellules. Il a été réalisé en étroite collaboration avec les experts, qui ont validé les annotations afin de garantir que les données d'entraînement destinées aux modèles soient de haute qualité et scientifiquement fiables.
4. Modélisation : Après la préparation des données, nous avons commencé à déployer des modèles de deep learning pour la classification automatique de *Karenia selliformis*. Plusieurs modèles ont été testés, ajustés et validés à chaque itération, en collaboration directe avec des experts en biologie. Cette démarche itérative a favorisé une amélioration continue de la précision des modèles, conformément aux principes de la méthodologie Agile.
5. Évaluation : À la fin de chaque itération de modélisation, les résultats ont été analysés par les experts. Cette évaluation a porté sur la précision, la qualité de la détection et de la classification des microalgues. Les retours des experts ont conduit à des ajustements des modèles, garantissant ainsi que les résultats finaux étaient conformes aux attentes et aux exigences définies lors de la première phase.
6. Déploiement : Après avoir été évalué par les biologistes, le modèle est mis en place dans un environnement opérationnel pour surveiller sa performance dans la détection de cette microalgue toxique.

1.4.2 Intégration des principes agile

Le projet a été initialement organisé selon les six phases de la méthodologie CRISP-DM, mais nous avons intégré des principes de la méthode Agile pour accroître la flexibilité et permettre des ajustements continus tout au long de son déroulement. Cette approche Agile a permis de prendre en considération les retours réguliers des experts en biologie et d'incorporer de nouvelles données au fur et à mesure, assurant ainsi que les résultats correspondent aux exigences changeantes du projet. Voilà comment la méthode Agile a été intégrée dans les différentes phases de CRISP-DM :

- Compréhension des objectifs et des données : lors de chaque cycle d'analyse des besoins ou de compréhension des données, des réunions fréquentes avec les experts en biologie ont facilité l'ajustement des objectifs du projet en fonction des nouvelles exigences ou des données fournies.
- Préparation des données : Le processus d'annotation des images s'est déroulé en plusieurs cycles, chaque série étant soigneusement examinée et corrigée par les experts avant de passer à l'étape suivante.
- Modélisation et évaluation : Après chaque itération, les modèles ont été finement ajustés et évalués, avec une validation des résultats par les experts. Les retours des biologistes ont permis d'apporter des modifications continues visant à optimiser la précision et la pertinence des modèles.
- Déploiement : Même au cours de la phase de déploiement, des ajustements finaux ont été effectués au résultat afin d'assurer qu'elle réponde parfaitement aux attentes des utilisateurs finaux et d'améliorer leur processus de prise de décision.

Cette intégration de CRISP-DM et de la méthode Agile nous a permis de maintenir une rigueur dans notre approche tout en restant flexibles face aux évolutions. Cela a garanti que le projet soit réalisé avec des résultats précis, répondant aux exigences des parties prenantes.

1.5 Conclusion

En conclusion, ce chapitre a établi les fondations nécessaires à la compréhension de notre projet. Nous avons présenté l'organisme d'accueil, réalisé une analyse approfondie de l'existant et identifié les défis à relever ainsi que les objectifs à atteindre, sans oublier la solution proposée. Une méthodologie a également été établie pour organiser efficacement la mise en œuvre du projet, ainsi l'explication des concepts biologiques et technologiques fondamentaux. Ce cadre général prépare le terrain pour les chapitres suivants, où nous examinerons en détail les aspects techniques et le développement du projet. Le chapitre suivant se penchera sur l'état de l'art et les recherches pertinentes dans ce domaine.

État de l'art et présentation des techniques utilisées

Sommaire

2.1	Introduction	23
2.2	Intelligence artificielle	23
2.2.1	Apprentissage automatique	24
2.2.2	Apprentissage profond	24
2.2.3	Réseau de neurones convolutifs	25
2.2.4	Architecture de CNN particulières	27
2.3	Revue de la littérature scientifique	30
2.4	Synthèse	40
2.5	Conclusion	43

2.1 Introduction

Afin de dépasser les limitations inhérentes à la cytométrie en flux pour la détection et la classification des microalgues, l'intégration de l'intelligence artificielle (IA) se révèle être une perspective particulièrement prometteuse. Ce chapitre a pour objectif de présenter les fondements de l'IA et les travaux existants dans ce domaine à travers une revue approfondie de la littérature scientifique, tout en soulignant les récents progrès et les lacunes. Cette analyse offrira un cadre pour comprendre les défis actuels et les besoins spécifiques guidant le développement de solutions innovantes pour la surveillance et la protection des écosystèmes marins.

2.2 Intelligence artificielle

"L'intelligence artificielle (IA) est un ensemble de théories et de techniques visant à réaliser des machines capables de simuler l'intelligence humaine¹. Souvent classée dans le domaine des mathématiques et des sciences cognitives, l'IA fait appel à des disciplines telles que la neurobiologie computationnelle (qui a notamment inspiré les réseaux neuronaux artificiels), les statistiques, ou l'algèbre linéaire. Elle vise à résoudre des problèmes à forte complexité logique ou algorithmique. Par extension, dans le langage courant, l'IA inclut les dispositifs imitant ou remplaçant l'homme dans certaines mises en œuvre de ses fonctions cognitives." [10]

L'IA occupe aujourd'hui une place essentielle dans divers domaines, de la reconnaissance d'images à la prise de décision automatisée. Son intégration croissante dans les technologies modernes vise à améliorer l'efficacité, la précision et à automatiser des tâches complexes, facilitant ainsi des avancées majeures dans de nombreux secteurs.




FIGURE 2.1 – Schéma des relations entre l'intelligence artificielle, l'apprentissage automatique et l'apprentissage profond [10]

2.2.1 Apprentissage automatique

L'apprentissage automatique, ou machine learning, est une branche de l'intelligence artificielle qui utilise des méthodes mathématiques et statistiques pour permettre aux ordinateurs de s'améliorer dans des tâches spécifiques en apprenant à partir de données, sans avoir besoin d'instructions précises pour chaque tâche. Le processus se divise en deux phases principales : la phase d'entraînement, où le modèle est construit à partir d'un ensemble de données pour accomplir diverses tâches, et la phase de production, où le modèle est utilisé pour traiter de nouvelles données.

Il existe plusieurs méthodes d'apprentissage selon le type de données : supervisé (avec données étiquetées), non supervisé (sans étiquettes), semi-supervisé, auto-supervisé (le modèle génère ses propres étiquettes) et par renforcement (le modèle apprend par récompense). Ces techniques peuvent s'appliquer à des données variées, simples ou complexes [11].

2.2.2 Apprentissage profond

L'apprentissage profond (Deep Learning) est une sous-catégorie de l'apprentissage automatique qui utilise des réseaux de neurones artificiels à plusieurs couches pour analyser des données complexes. Inspiré par le fonctionnement du cerveau humain, il est particulièrement

efficace pour traiter des données non structurées telles que des images et du texte. L'apprentissage profond a permis des avancées significatives dans des domaines comme la reconnaissance d'images et la traduction automatique, en offrant une précision et une performance supérieures dans l'interprétation des données [12].

L'apprentissage profond comprend deux types principaux de réseaux de neurones : les réseaux de neurones artificiels classiques et les réseaux de neurones convolutifs (CNN). Les réseaux de neurones artificiels peuvent être utilisés pour divers types de tâches, mais pour l'identification et la classification d'images, les CNN sont particulièrement adaptés. Ils se distinguent par leur capacité à extraire automatiquement des caractéristiques visuelles importantes grâce à des couches de convolution qui capturent les motifs dans les données visuelles de manière hiérarchique. Cela rend les CNN idéaux pour le traitement d'images en deep learning, car ils permettent une classification et une détection précises des objets dans des données complexes et non structurées.

2.2.3 Réseau de neurones convolutifs

Les réseaux de neurones convolutifs (CNN), également appelés réseaux convolutifs profonds, sont largement utilisés en vision par ordinateur. Inspirés du fonctionnement du cortex visuel humain, les CNN sont spécifiquement conçus pour traiter les données visuelles de manière efficace. Grâce à leurs couches de convolution, ce qui les rend particulièrement performants dans des domaines tels que la reconnaissance d'images, la classification d'objets et l'analyse d'images médicales [13].




FIGURE 2.2 – Réseau de neurones convolutif [14]

Le réseau CNN est constitué de trois types de couches principales : une couche de convolution, une couche de regroupement (pooling) et une couche entièrement connectée (FC). Ces couches peuvent être empilées plusieurs fois pour former l'architecture du réseau.

1. **Couche de convolution** : La couche de convolution est le cœur des réseaux de neurones convolutifs (CNN), essentielle dans la vision par ordinateur et le traitement d'images. Elle utilise des filtres (ou noyaux) pour balayer l'image et détecter des motifs comme les bords, les textures, et d'autres caractéristiques visuelles. En appliquant plusieurs filtres dans une seule couche de convolution, le CNN peut identifier des caractéristiques de plus en plus complexes et abstraites à différentes échelles
2. **Couche de regroupement (Pooling)** : Après la couche de convolution, la couche de regroupement (pooling) est utilisée pour réduire la dimension spatiale des données tout en conservant les caractéristiques les plus importantes. Cela permet de diminuer la complexité du modèle tout en préservant l'information essentielle.
3. **Couche entièrement connectée (FC)** : Une fois les caractéristiques extraites par les couches de convolution et de pooling, elles sont aplaties et transmises à une ou plusieurs couches entièrement connectées pour générer les prédictions finales. Ces couches, constituées de neurones interconnectés, de poids et de biais, forment généralement les dernières étapes d'un CNN avant la couche de sortie.
4. **Dropout et fonctions d'activation** : En plus des couches principales, deux concepts importants sont intégrés :

- **Dropout** : C'est une technique utilisée pour prévenir le surapprentissage dans les réseaux de neurones. Lors de l'entraînement, certains neurones sont désactivés de façon aléatoire, ce qui réduit la complexité du modèle tout en améliorant ses performances. Cela permet d'optimiser les résultats du modèle, comme illustré dans la figure ci-dessous.




FIGURE 2.3 – La technique de Dropout [15]

- **Fonctions d'activation** : Les fonctions d'activation sont des outils mathématiques utilisés dans les réseaux de neurones pour introduire de la non-linéarité, déterminer quelles informations doivent être activées ou inhibées, et approximer des relations complexes entre les variables du réseau. Les fonctions d'activation couramment utilisées sont Relu (pour Rectified Linear Unit), Softmax, tanH (pour Tangente hyperbolique) et Sigmoid. Elles jouent un rôle crucial dans la classification binaire et multiclasse des modèles CNN.

2.2.4 Architecture de CNN particulières

Les architectures particulières de réseaux de neurones convolutifs (CNN) ont été développées pour répondre à des besoins spécifiques dans le domaine de la vision par ordinateur. Chaque architecture apporte des innovations distinctes qui ont influencé l'évolution de la reconnaissance d'images et d'autres tâches associées. Voici quelques exemples notables :

- **ResNet (Residual Network)** : ResNet a résolu le problème de la dégradation des performances avec l'augmentation de la profondeur des CNN en utilisant des connexions résiduelles, permettant un entraînement efficace de réseaux très profonds.

- **VGGNet** : Reconnu pour sa profondeur, VGGNet se compose de 16 à 19 couches de convolution, ce qui a permis d'améliorer la précision de la classification en introduisant un modèle plus simple et uniforme.
- **GoogLeNet (Inception)** : Cette architecture a introduit les modules Inception, combinant des filtres de différentes tailles pour capturer des caractéristiques à diverses échelles, optimisant ainsi l'utilisation des ressources et la performance.
- **EfficientNet** : Cette architecture est basée sur un équilibre entre la profondeur, la largeur et la résolution des modèles, visant à maximiser les performances avec des ressources limitées.
- **MobileNet** : Conçu pour les dispositifs mobiles et les applications à faible consommation d'énergie, MobileNet utilise des couches de convolution légères pour maintenir une bonne précision tout en étant efficace en termes de ressources.
- **Xception** : Le modèle Xception contient 71 couches de convolution. Il est structuré en plusieurs blocs de convolutions séparables en profondeur, optimisés pour réduire les paramètres et améliorer la performance en classification et segmentation d'images.
- **NASNetMobile** : Le modèle NASNetMobile comprend environ 88 couches, optimisées pour offrir une bonne précision tout en étant léger et rapide, idéal pour les appareils mobiles et les systèmes embarqués. Grâce à sa structure modulaire, obtenue par recherche d'architecture neuronale (NAS), NASNetMobile est particulièrement utile pour des applications de classification d'images en temps réel dans des environnements à ressources limitées.

YOLO (You Only Look Once)

YOLO (You Only Look Once) est un modèle de deep learning basé sur des réseaux de neurones convolutionnels (CNN), spécialement conçu pour la détection d'objets en temps réel. YOLO se distingue par sa capacité à traiter une image entière en une seule passe, ce qui le rend extrêmement rapide et efficace par rapport aux méthodes traditionnelles qui analysent l'image en plusieurs étapes. Il existe plusieurs versions de Yolo :

- **YOLOv1** : La première version de YOLO, divise une image en une grille de 7x7 et prédit des boîtes de délimitation et des classes d'objets pour chaque cellule. Cette approche

unifiée permet une détection rapide en temps réel, mais manque de précision pour les petits objets et les objets proches.

- **YOLOv2** : YOLOv2 introduit des améliorations, comme les Anchor Boxes et la Batch Normalization, pour une meilleure précision et la capacité de détecter plus de 9000 classes. La résolution d'entrée a été augmentée pour de meilleures performances, ce qui rend YOLOv2 plus précis et rapide.
- **YOLOv3** : Cette version utilise une architecture plus profonde avec Darknet-53 et introduit une détection multi-échelle pour mieux identifier les objets de différentes tailles. YOLOv3 est plus précis, en particulier pour les petits objets, tout en conservant une grande vitesse.
- **YOLOv4** : intègre des techniques avancées comme la Mosaic data augmentation, Self-adversarial training, et les connexions CSP, augmentant encore la précision et l'efficacité pour les applications en temps réel, tout en exploitant au mieux les GPU modernes.
- **YOLOv5** : est implémenté en PyTorch et propose plusieurs tailles de modèles (s, m, l, x) pour un compromis entre vitesse et précision. C'est une version populaire pour sa facilité d'utilisation et ses mises à jour régulières.
- **YOLOv6** : offre des performances élevées avec des optimisations en termes de vitesse et de précision. Cette version est adaptée aux applications nécessitant une haute performance en temps réel.
- **YOLOv7** : propose de nouvelles techniques comme les repulsed bounding boxes et la batch normalization fusionnée, ce qui améliore la précision et l'efficacité. Cette version est plus robuste pour différentes conditions et optimisée pour les GPU modernes.
- **YOLOv8** : est conçu pour une meilleure modularité et flexibilité. Avec des améliorations dans la gestion des objets de petite taille et des scènes complexes, il est adapté pour diverses tâches et compatible avec les environnements mobiles et embarqués.

Ces architectures représentent des étapes clés dans l'évolution des CNN, chacune apportant des innovations qui ont élargi les possibilités d'application et amélioré les performances des réseaux de neurones convolutifs.

2.3 Revue de la littérature scientifique

De nombreux chercheurs ont exploré l'application de l'intelligence artificielle pour la détection des microalgues, une technologie prometteuse pour améliorer la précision et la rapidité de ces analyses. Diverses études se sont concentrées sur le développement de modèles robustes et de techniques d'apprentissage profond adaptées aux caractéristiques uniques des microalgues.

Parmi les recherches menées, certains chercheurs ont exploré la combinaison de l'apprentissage profond avec l'apprentissage automatique pour améliorer la classification et la reconnaissance des microalgues. Par exemple, les chercheurs turcs Sonmez et al.[16] ont associé des réseaux de neurones convolutionnels (CNN) tels que MobileNet et GoogleNet avec des machines à vecteurs de support (SVM) pour classifier différentes espèces de microalgues. En testant quatre fonctions de noyau SVM sur un ensemble de 7820 images, le noyau linéaire s'est révélé le plus performant avec un taux de réussite de 98,79%, suivi des noyaux RBF (98,73%), polynomial (97,84%) et sigmoïde (97,20%). L'approche combinée CNN-SVM permet non seulement d'améliorer la classification des microalgues, mais aussi de fournir une base pour des applications en temps réel dans la surveillance écologique et la conservation, en réponse aux défis du changement climatique et de la pollution.

Aussi, en Malaisie, Chong et al.[17] ont opté pour la combinaison d'apprentissage automatique (ML) SVM et k-NN avec l'apprentissage profond (DL) CNN pour la classification des microalgues, en se concentrant sur les caractéristiques morphologiques et texturales de 3150 images capturées via microscopie optique. Les algorithmes SVM et k-NN ont été utilisés pour l'extraction des caractéristiques de forme et de texture, atteignant des précisions maximales de 97,63% et 96,93%, respectivement. Le modèle CNN a surpassé ces approches, atteignant une précision de 97,86% avec un seuil de probabilité de 80%. Aussi les résultats ont montré que les caractéristiques géométriques surpassaient les caractéristiques de texture en termes de précision (95,38% contre 90,41%), notamment en raison de la facilité de distinction des formes par rapport aux textures. Cette étude montre que l'intégration de techniques d'intelligence artificielle, telles que les réseaux neuronaux convolutionnels, peut grandement améliorer la

classification des microalgues, accélérant ainsi les efforts de surveillance et d'analyse en temps réel des écosystèmes marins

D'autres chercheurs ont choisi d'utiliser seulement le deep learning. Parmi ces travaux, on peut citer en Chine, des chercheurs [18] ont développé un modèle de réseau neuronal convolutionnel à double branche, appelé SI-DBNet, pour l'identification des espèces à partir de données multimodales, combinant des spectres Raman et des images. Ce modèle vise à classifier efficacement les microalgues. Pour les analyses monomodales, D-EcaNet a été utilisé pour les spectres Raman, atteignant une précision de 90,6%, tandis que ResNet34 a permis une précision de 92,2% sur les images. En intégrant des convolutions dilatées et des mécanismes d'attention de canal, le modèle SI-DBNet a surpassé ces approches, avec une précision globale remarquable de 98,8%

Une étude menée en Inde par Pant et al.[19] a utilisé un modèle de réseau neuronal convolutionnel (CNN) basé sur la topologie ResNeXt pour l'identification et la classification automatisées de sept espèces de *Pediastrum*, en s'appuyant sur une vaste base de données de 42 000 images d'algues. Ce modèle utilise des caractéristiques spécifiques des algues, telles que la formation des cénobia, la disposition cellulaire et les sculptures sur la paroi cellulaire. La modification de la topologie ResNeXt a permis de réduire le nombre de paramètres de 23 à 9 millions, en ajustant notamment la taille du filtre de 7×7 à 5×5 . Avec une précision de classification de 98,45% et un score F1 supérieur à 0,98, L'étude souligne également l'importance de l'utilisation des filtres adaptés pour traiter des images aux caractéristiques morphologiques complexes, avec des résultats très prometteurs pour la classification d'espèces de *Pediastrum* à l'aide de réseaux de neurones profonds.

En 2023, Sonmez et al.[20] ont évalué plusieurs modèles de réseaux neuronaux convolutionnels (CNN) pour la classification des microalgues à partir d'images obtenues par microscopie optique (LM) et microscopie électronique à balayage (SEM). Les modèles testés incluaient VGG16, MobileNet V2, Xception, NasnetMobile et EfficientNetV2, appliqués sur deux espèces de cyanobactéries et trois espèces de chlorophytes. VGG16 et EfficientNetV2 se sont démarqués avec une précision de 99% pour les deux types d'images. En revanche, NasnetMobile a montré les résultats les plus faibles, avec une précision de 87% pour les images

SEM, tandis que MobileNet V2 et Xception ont atteint des performances élevées avec des précisions supérieures à 93%. L'efficacité de VGG16 et d'EfficientNetV2 dans la classification des microalgues, avec des scores F1 et AUC de 0,99 et 1,00 respectivement, met en évidence la robustesse de ces modèles pour l'analyse d'images de microalgues.

Dans la plupart des articles ils ont utilisé le modèle YOLO. les chercheurs ZHENG et al.[21] ont employé YOLOv5 pour créer une plateforme microfluidique automatisée et intelligente (AIMP) dédiée à la détection et à la surveillance améliorées des microalgues. Cette plateforme intègre un microscope USB portable, une platine motorisée XYZ, et un micro-ordinateur Raspberry Pi 4B, permettant une détection en temps réel sur le terrain. Pour entraîner le réseau de détection des espèces de microalgues (MSDN), un ensemble de 812 images a été constitué, incluant 630 images de *Cosmarium*, 770 de *Closterium*, 737 de *Haematococcus pluvialis* et 736 de *Micrasterias*. Le modèle YOLOv5 utilisé a obtenu une précision moyenne de 92,8% pour l'identification des microalgues. La plateforme a montré une haute précision dans la détection et la classification, et sa portabilité la rend idéale pour une utilisation sur le terrain, offrant une solution économique et efficace pour les études écologiques et l'exploitation commerciale des microalgues.

Même des chercheurs en China [22] ont développé AlgaeSeg-YOLO, un réseau neuronal convolutionnel spécialement conçu pour l'identification, la quantification et la segmentation des contours des microalgues. En utilisant une base de données de 2799 images annotées couvrant six espèces de microalgues nuisibles, soit 3916 instances, ce modèle a atteint une précision moyenne (mAP) de 95,61%. AlgaeSeg-YOLO s'est avéré supérieur à d'autres modèles de référence, tels que YOLOv8n-seg, YOLOv5n-seg, Mask R-CNN, Cascade Mask R-CNN, et SOLOv2. Cette étude pave la voie vers une analyse automatisée des microalgues, réduisant ainsi les coûts de main-d'œuvre et fournissant un soutien technique pour la surveillance à long terme de l'environnement écologique.

Une autre étude en Chine réalisé par DUAN et al.[23] a introduit RWD-YOLO, une version améliorée de YOLO v5 s, intégrant un module d'amélioration du champ réceptif (RFE), une fonction de perte dynamique Wise-IoU v3, et une tête dynamique (Dyhead). Ce modèle a été testé sur une base de données de 1011 images de six types courants d'algues : *Pediastrum*,

Scenedesmus, Coelastrum, Cymbella, Oocystis et Microcystis. Les résultats expérimentaux montrent que RWD-YOLO atteint une précision de 89,1%, surpassant les performances de modèles de référence tels que Faster R-CNN et SSD.

Les recherches scientifiques ne se sont pas limitées aux écosystèmes marins. Elles ont également ciblé les eaux de ballast des navires, identifiées comme une des principales sources de propagation de nouvelles espèces de microalgues exotiques. En Chine, des chercheurs [24] ont développé une méthode de détection des microalgues dans ces eaux, basée sur une version optimisée de YOLOX. Grâce à un ensemble de données enrichi avec StyleGAN3 amélioré, l'algorithme EOA (Enhanced Object Algorithm) offre des performances accrues. Les résultats expérimentaux montrent une précision de détection de 82,1% .

Un autre exemple notable [25] dans ce contexte aussi pour identifier les microalgues dans l'eau de ballast basée sur un modèle YOLOv3 amélioré. La méthode utilise d'abord un réseau léger, MobileNet, à la place du réseau Darknet-53 en tant que réseau principal d'extraction des caractéristiques dans le modèle YOLOv3 original. Ensuite, une amélioration du "spatial pyramid pooling" (SPP) est introduite pour agréger et concaténer les caractéristiques régionales multi-échelles afin de réduire l'erreur de position lors de la détection de petits objets. Puis, en tenant compte de la zone de chevauchement de la boîte englobante, de la distance du point central et du rapport d'aspect, l'algorithme "Complete IoU" (CIoU) est utilisé pour optimiser la fonction de perte du modèle YOLOv3. Enfin, la méthode proposée est comparée expérimentalement à d'autres méthodes récentes sur un ensemble de données établi. Les résultats expérimentaux ont montré que, dans les mêmes conditions, ce modèle YOLOv3 amélioré atteint une précision moyenne de 98,90 %, et l'efficacité de détection est supérieure de 8,59 % à celle du modèle YOLOv3 original.

Dans une autre étude[26], les chercheurs Chinois ont proposé une méthode de détection basée sur YOLOx-s a été proposée, utilisant un ensemble de données d'images multi-échelles et multi-morphologiques (incluant les espèces *Chlorella sorokiniana* obtenue à Taipei, *Scenedesmus quadricauda* achetée dans la région de Yancheng, et *Spirulina platensis* obtenue de l'Institut d'hydrobiologie de l'Académie chinoise des sciences). Le modèle YOLOx amélioré a montré des performances élevées, atteignant une précision de 95,93%. En comparaison avec

les modèles YOLOx-s d'origine, le YOLOx amélioré a augmenté le mAP de 3,33%. Ces résultats démontrent que l'apprentissage profond et les méthodes de détection d'objets offrent de nouvelles opportunités pour les bioprocédés basés sur les microalgues.

ZHOU et al.[27] ont proposé un nouvel ensemble de données pour la détection des microalgues marines, comprenant des images de différents genres d'algues, ainsi que des échantillons dans divers états physiologiques. L'ensemble de données simule des conditions réelles en intégrant des images d'échantillons d'eau mélangés dans l'ensemble de test. Ils ont entraîné, validé et testé plusieurs algorithmes, dont TOOD, YOLOv5, YOLOv8 et des variantes de RCNN, sur cet ensemble de données. Les résultats montrent que les modèles de détection d'objets, qu'ils soient à une ou deux étapes, atteignent une précision moyenne élevée, démontrant ainsi la capacité de la vision par ordinateur à détecter efficacement les microalgues. Les modèles YOLOv5 et YOLOv8 se sont révélés particulièrement performants pour la classification et la localisation des cellules de microalgues. Le mAP (IoU = 0,5) des algorithmes YOLO a surpassé celui des autres méthodes, indiquant une meilleure précision dans la localisation des objets. Malgré les défis liés à la haute résolution des images, à la petite taille de l'ensemble d'entraînement et à l'absence d'équilibre dans les classes, les résultats montrent que les algorithmes modernes de vision par ordinateur sont prometteurs pour la détection en temps réel des microalgues

En Corée, ABDULLAH et al.[28] ont utilisé différentes versions du réseau neuronal convolutionnel YOLOv3, YOLOv4 et YOLOv5 pour détecter et classer la prolifération d'algues nuisibles (HAB) à partir d'images microscopiques en quatre classes. Avec un ensemble de données de 1600 images de *Cosmarium*, *Scenedesmus*, *Closterium* et *Spirogyra* doublés à 3200 images grâce à l'augmentation par DC-GAN.. La précision obtenue pour YOLOv3, YOLOv4 et YOLOv5 est respectivement de 75,3%, 83,0% et 91,0%.

D'autres chercheurs en Corée, PARK et al.[29] ont essayé de surveiller les proliférations d'algues afin de protéger les systèmes d'approvisionnement en eau potable en comparant quatre modèles YOLO v3, YOLO v3-tiny, YOLO v4 et YOLO v4-tiny en utilisant des images de cellules de 30 genres d'algues pour l'entraînement et les tests. Les résultats montrent que la précision des modèles est respectivement de 40,9%, 88,8%, 84,4% et 89,8%, ce qui prouve

que YOLO v4 surpasse YOLO v3. Les modèles minuscules se distinguent par une précision supérieure et un temps de détection d'objet jusqu'à dix fois plus rapide que les versions standard. Cette étude confirme que les modèles de détection de cellules algales basés sur YOLO, en particulier les versions minuscules, offrent des performances pratiques et adaptées à la surveillance de la qualité de l'eau

Également en Corée, d'autres chercheurs [30] ont utilisé YOLOv3 pour développer un modèle de détection d'images d'algues. Sur une base de 1 114 images d'algues représentant 30 genres, collectées au microscope. Les images d'algues ont été divisées en quatre groupes comprenant cinq, 10, 20 et 30 genres pour entraîner et tester le modèle. La précision pour les quatre genres était respectivement de 81%, 70%, 52% et 41 % .

Les chercheurs chinois ont développé plusieurs modèles pour automatiser la classification des microalgues [31]. Parmi ceux-ci, Algae-YOLO propose une approche améliorée pour la détection des algues, en utilisant ShuffleNetV2 comme réseau dorsal afin de réduire la taille des paramètres. Ce modèle intègre également un mécanisme d'attention ECA pour améliorer la précision. De plus, un module de convolution fantôme est employé pour optimiser la structure du cou, contribuant ainsi à la réduction de la taille des paramètres. La base de données utilisée pour ce modèle comprend 10 000 images, incluant des photographies de *Chlorella* sp., *Isochrysis* sp., des algues mixtes et des images masquées. La précision d'Algae-YOLO atteint 82,3%, soit une légère baisse de 0,007 par rapport à celle de YOLOv5.

Le tableau ci-dessous présente un récapitulatif des travaux réalisés pour la détection des microalgues.

Références	Années	Pays	Base données	Méthodes	Résultats
[17]	2024	Chine	Total de huit échantillons de minéraux : la calcite, la sidérite, l'anhydrite, le gypse, la barytine, le talc, la magnétite et la magnésite	SI-DBNet, D-EcaNet et ResNet34	D-EcaNet 90,6% ResNet34 92,2% SI-DBNet 98,8%
[15]	2024	Turquie	Six espèces différentes de microalgues (<i>N. amabilis</i> , <i>E. pusilla</i> , <i>N. varingica</i> , <i>O. neapolitana</i> , <i>P. parvum</i> et <i>S. subsalsa</i>) Ensemble de données de 7820 images	MobileNet et GoogleNet, associés à la classification SVM	Noyau linéaire 98,79% Noyau RBF 98,73% Noyau polynomial 97,84% Noyau sigmoïde 97,20%
[16]	2024	Malaisie	Total de 3150 images de trois milieux de culture différents tels que Zarrouk, BG-11 et AF6 la collection de cultures microbiennes de l'Institut national d'études environnementales (MCC-NIES)	SVM et k-NN CNN	SVM 97,63% K-NN 96,93% CNN 97,86%

[20]	2024	UK	Total de 2873 images de Cosmarium, Closterium, Haematococcus pluvialis et Microasterias a été porté à 5003 après augmentation.	YOLOv5	YOLOv5 92,8%
[21]	2024	Chine	2799 images annotées de six espèces de microalgues nuisibles	AlgaeSeg-YOLO	AlgaeSeg-YOLO 95,61%
[22]	2024	Chine	1011 images d'algues englobent six types courants Pediastrum, Scenedesmus, Coelastrum, Cymbella, Oocystis et Microcystis	Modèle amélioré de YOLOv5s RWD-YOLO	RWD-YOLO 89,1%
[19]	2023	Turquie	Des images de microscopie optique (LM) et de microscopie électronique à balayage (SEM) de deux espèces de cyanobactéries et de trois espèces de chlorophytes	VGG16, MobileNet V2, Xception, NasnetMobile et EfficientNetV2	VGG16 99% EfficientNetV2 99% MobileNet V2 93% Xception 93% NasnetMobile 87%
[23]	2023	Chine	Ensemble de données enrichi grâce à un StyleGAN3	Amélioration de YOLOX	YOLOX 82,1%
[25]	2023	Chine	Les espèces : Chlorella sorokiniana, Scenedesmus quadricauda et Spirulina platensis	YOLOx amélioré	YOLOx 95,93%
[26]	2023	Chine	Contient 967 images de six genres Pinnularia , Chlorella , Platymonas , D. salina , Isochrysis et Symbiodinium	TOOD, YOLOv5, YOLOv8 et des variantes de RCNN	YOLOv5 et YOLOv8 sont plus performants
[27]	2022	Korea	Total de 1600 images de Cosmarium, Scenedesmus, Closterium et Spirogyra Après l'augmentation avec DC-GAN, le nombre est passé à 3200	YOLOv3, YOLOv4 et YOLOv5	YOLOv3 75,3% YOLOv4 83,0% YOLOv5 91,0%
[30]	2022	Chine	Ensemble de données de 10 000 images, comprenant des photographies de Chlorella sp., Isochrysis sp., des algues mixtes, et des images masquées	Algae-YOLO et ShuffleNetV2	Algae-YOLO 82,3%
[28]	2022	Korea	Des images de cellules de 30 genres d'algues	YOLO v3, YOLO v3-tiny, YOLO v4 et YOLO v4-tiny	YOLO v3 40,9% YOLO v3-tiny 88,8% YOLO v4 84,4% YOLO v4-tiny 89,8%
[29]	2021	Korea	Un total de 1 114 images d'algues représentant 30 genres Les images d'algues ont été divisées en quatre groupes comprenant cinq, 10, 20 et 30 genres	YOLOv3	YOLOv3 Cinq genres 81% Dix genres 70% Vingt genres 52% Trente genres 41%
[24]	2021	Chine	les microalgues dans l'eau de ballast	MobileNet YOLOv3 amélioré	YOLOv3 98,9%
[18]	2020	Inde	Sept espèces de Pediastrum 42 000 images Sources Internet en libre accès http://www-cyanosite.bio.purdue.edu/images/images.html https://atlasofcyanobacteria.com/index	ResNeXt	ResNeXt 98,45%

Tandis que certaines études ont employé des techniques microscopiques pour la classification des microalgues, d'autres recherches se sont tournées vers la cytométrie en flux d'imagerie, exploitant ses capacités pour capturer des informations détaillées et diversifiées sur les cellules en vue de classifications plus précises.

Parmis eux en Australie, une étude [32] a mis en œuvre un réseau neuronal à impulsions convolutionnelles (SNN) combiné au modèle YOLOv3, nommé SNN-YOLO, pour

la classification et la détection de cellules sans marquage en vision neuromorphique. La base de données contient des microparticules de polystyrène ainsi que des lignées cellulaires THP-1 et LL/2. Comparativement au modèle YOLOv3 classique, SNN-YOLO a démontré une performance supérieure, atteignant une précision moyenne de classification de 97,4% contre 96,2% pour YOLOv3.

LUO et al.[33] ont développé un système basé sur la cytométrie en flux d'imagerie, couplé à un réseau neuronal profond nommé MCellNet, pour la détection de *Cryptosporidium* et *Giardia* dans l'eau potable. La base de données utilisée comprend 80 146 images, réparties entre *Cryptosporidium*, *Giardia* et des billes microplastiques. Le modèle MCellNet a atteint une précision de classification supérieure à 99,6%, surpassant ainsi d'autres algorithmes tels que MobileNetV2. Le pipeline combine l'imagerie à grande vitesse et les réseaux neuronaux profonds pour améliorer les performances tout en consommant peu d'énergie. Les auteurs soulignent également la nécessité d'améliorer les performances du modèle pour les données inconnues et proposent des pistes comme l'apprentissage métrique et bayésien

Une revue exhaustive réalisée par des chercheurs singapouriens en 2021 [34] explore en profondeur les développements récents dans le domaine de la cytométrie en flux d'imagerie (IIFC) assistée par apprentissage automatique. L'apprentissage profond a révolutionné l'analyse des données en cytométrie de flux, notamment pour les tâches de classification et de segmentation d'images cellulaires. Des modèles tels que Faster-RCNN, SSD et U-Net sont utilisés pour détecter, suivre et segmenter des cellules dans les flux d'imagerie. Les limites de ces technologies sont souvent liées à la puissance de calcul nécessaire pour traiter de grandes quantités de données en temps réel, ce qui représente un défi pour les systèmes à grande échelle. L'article met en avant l'importance de l'optimisation des algorithmes pour améliorer la précision et la vitesse d'analyse, tout en tenant compte des coûts et de la consommation énergétique associés aux GPU haut de gamme nécessaires pour exécuter ces modèles. Des avancées futures sont attendues, notamment avec des algorithmes tels que YOLO récurrent et SiamMask, qui pourraient encore améliorer les performances.

Au Japon, des chercheurs [35]. ont utilisé la cytométrie en flux par imagerie de fluorescence multiplexée combinée à un algorithme de machine learning basé sur les machines à vecteurs

de support (SVM) pour classifier six espèces de microalgues avec précision. La base de données utilisée comprend 8 640 cellules imagées (1 440 par espèce), chaque cellule étant capturée en trois images (fluorescence et champ clair), soit un total de 25 920 images. En exploitant 251 caractéristiques extraites des images multicolores, la classification a atteint une précision exceptionnelle de 99,8%. En revanche, l'utilisation de seulement 87 caractéristiques morphologiques issues des images en champ clair a réduit la précision à 89,5%, et en l'absence d'informations morphologiques, celle-ci est descendue à 84,9%.

D'autres chercheurs en Allemagne [36] ont combiné la cytométrie de flux d'imagerie à haut débit avec des techniques d'apprentissage profond pour l'identification des espèces de phytoplancton et des stades de leur cycle de vie. L'identification et le comptage des espèces de phytoplancton constituent des étapes cruciales dans l'évaluation de la qualité de l'eau, en particulier pour les réservoirs d'eau potable, les zones de baignade et les eaux de ballast, qui nécessitent une surveillance régulière des espèces nuisibles. Grâce à la cytométrie basée sur l'image, environ 47 000 images de fluorescence de Chl a ont été collectées à un grossissement de 60× pour neuf espèces communes de phytoplancton. Un réseau neuronal profond, appelé CNN (Convolutional Neural Network), a été formé sur ces images pour identifier les espèces et les stades de leur cycle de vie. Les résultats ont démontré le potentiel élevé de cette approche, avec une précision atteignant 97% .

La synergie entre la cytométrie en flux et l'intelligence artificielle ne se limite pas au domaine de la biologie marine et du phytoplancton, elle a également été appliquée dans le secteur de la santé pour la classification et la reconnaissance de diverses cellules humaines. Une étude menée en Chine par DU et al.[37] a développé une méthode pour la détection et le dénombrement des cellules tumorales circulantes (CTC) dans le sang périphérique, basée sur la cytométrie d'image en champ clair (BFIC) associée à une analyse de corrélation multi-images (MFIC). Cette méthode utilise un large canal microfluidique permettant un flux élevé de 50 000 cellules par minute, sans obstruction. Un réseau neuronal profond, YOLO-V4, a été employé pour identifier trois lignées cellulaires cancéreuses (HT29, A549, KYSE30), atteignant une précision impressionnante de 99% .

En Suisse, des chercheurs [38] ont employé iCellCnn, une méthode d'apprentissage profond faiblement supervisée, pour le diagnostic des maladies hématologiques en utilisant des données de cytométrie de flux d'imagerie (IFC). iCellCnn se distingue en exploitant des images non annotées et sans marquage, offrant ainsi une approche plus pratique et directement applicable en clinique. L'étude met en évidence l'efficacité de cette méthode pour diagnostiquer le syndrome de Sézary (SS) à partir d'images de cellules T, obtenues après tri cellulaire par activation de fluorescence, avec une précision remarquable de 100% .

Une autre étude aux États-Unis a mis au point un système innovant utilisant l'apprentissage profond pour la classification en temps réel des cellules en cytométrie de flux. Cette approche repose sur un réseau neuronal convolutionnel (CNN) inspiré de VGGNet, capable de distinguer les globules blancs OT-II et les cellules cancéreuses épithéliales SW-480 sans recours au marquage. Avec une précision dépassant les 95%, cette méthode promet une classification rapide et précise, facilitant ainsi des applications cliniques en temps réel [39].

Le tableau ci-dessous offre un récapitulatif des études combinant l'intelligence artificielle et la cytométrie en flux pour la détection des microalgues

Références	Années	Pays	Base Données	Méthodes	Résultats
[31]	2024	Australia	des microparticules à base de polystyrène ainsi que des lignées cellulaires THP-1 et LL/2.	(SNN-YOLO) YOLOv3	SNN-YOLO 97,4% YOLOv3 96,2%
[36]	2022	China	Des images de cellules tumorales circulantes (CTC) des lignées cancéreuses HT29, A549 et KYSE30	YOLO-V4	YOLO-V4 99%
[33]	2021	Singapour		Faster-RCNN, SSD, U-Net, YOLO et SiamMask	
[32]	2021	Singapour	Total de 80146 images pour trois cellules Cryptosporidium, Giardia et des billes microplastiques	MCellNet	MCellNet 99,6%
[37]	2021	Switzerland	Images en champ clair de cellules T issues de PBMC de quatre donneurs sains et cinq patients atteints du syndrome de Sézary (SS)	iCellCnn	iCellCnn 100%
[34]	2020	Japon	total de 8 640 cellules ont été imagées (1 440 par espèce), chaque cellule étant capturée en trois images (fluorescence et champ clair), aboutissant à 25 920 images utilisées	SVM	251 caractéristiques 99,8% 0 caractéristiques 84,9% 87 caractéristiques 89,5%
[38]	2019	USA	Des globules blancs OT-II et des cellules cancéreuses épithéliales SW-480 sans marquage	VGGNet	VGGNet 95%
[35]	2018	Germany	46 797 images en fond clair et de 46 797 images de fluorescence de Chl a pour neuf espèces	CNN	CNN 97%

2.4 Synthèse

La revue de la littérature a permis d'explorer les approches et les technologies actuelles pour la détection et la classification des microalgues, avec une attention particulière aux modèles de deep learning et de machine learning. Dans cette section, nous discuterons des points forts et des limites des méthodes recensées, en les comparant aux besoins spécifiques de notre projet. Nous mettrons également en lumière les lacunes qui subsistent et les perspectives d'amélioration possibles, afin de situer notre contribution dans ce contexte.

Parmi les nombreuses méthodes de détection et de classification d'objets, le modèle YOLO (You Only Look Once) se distingue comme l'un des plus utilisés dans la littérature, notamment pour la classification des microalgues. De nombreux articles soulignent les performances

remarquables de YOLO [21], [22], [23], [24], [26], [27], [28], [31], [29], [30] [25], [32] et [37]. Cette popularité s'explique par ses performances remarquables en termes de rapidité et de précision, permettant une détection en temps réel qui est essentielle pour des applications pratiques. Les études montrent que YOLO excelle dans la gestion de données variées, y compris celles provenant de la microscopie, ce qui en fait un choix pertinent pour les projets visant à identifier et classer les microalgues. De plus, l'évolution constante des versions de YOLO, avec des améliorations continues en matière de précision et d'efficacité, témoigne de sa robustesse et de sa flexibilité.

De plus, les versions améliorées de YOLO, développées par les chercheurs, ont démontré une précision supérieure par rapport aux versions originales, notamment grâce à l'intégration de nouvelles architectures de réseaux et d'algorithmes d'optimisation avancés. Par exemple, des améliorations telles que l'utilisation de couches de convolution plus profondes et de mécanismes d'attention ont permis d'extraire des caractéristiques plus pertinentes des images, renforçant ainsi la capacité du modèle à détecter et classer les microalgues avec une plus grande exactitude. Cette tendance à l'amélioration des performances est bien illustrée dans les études réalisées par [26], [22], [25] et [32], où les auteurs rapportent des résultats significatifs en termes de précision, dépassant 95%, grâce à l'application des versions révisées de YOLO.

Aussi, les modèles de réseaux de neurones convolutifs (CNN) sont reconnus pour leur haute performance en termes de précision dans la détection et la classification des microalgues, et de nombreuses études en témoignent. Par exemple, Pant et al. [19] ont atteint une précision de 98,45% avec un modèle basé sur ResNeXt pour classer des images de *Pediastrum*, tandis que Sonmez et al. [20] ont montré qu'EfficientNetV2 et VGG16, deux architectures CNN, ont atteint des précisions de 99% sur des images de microscopie optique et électronique. Chong et al. [17] ont également démontré l'efficacité des CNN, avec un modèle qui a surpassé les approches traditionnelles SVM et k-NN pour la classification des microalgues, atteignant une précision de 97,86%.

Mais la majorité des articles examinés se basent sur diverses méthodes de détection et de classification, notamment celles utilisant des techniques d'imagerie avancées comme la microscopie optique et électronique. Cependant, il convient de noter que peu d'études

ont intégré la cytométrie en flux d'imagerie pour la classification des microalgues. Cette situation représente une opportunité significative pour la recherche, car la cytométrie en flux d'imagerie offre des avantages uniques, tels que la capacité à analyser rapidement un grand nombre de cellules individuelles et à fournir des informations détaillées sur les caractéristiques morphologiques des microalgues. La cytométrie en flux d'imagerie joue un rôle déterminant dans l'augmentation de la taille des bases de données d'images, permettant l'acquisition d'une quantité massive d'images de microalgues. Par exemple, l'étude de LUO et al [33] a constitué une base de données impressionnante de 80146 images de trois microalgues. En outre, KIM et al.[36] ont collecté environ 47 000 images en utilisant la cytométrie. De telles quantités de données permettent non seulement d'améliorer les performances des modèles d'apprentissage automatique, mais aussi de renforcer la précision des classifications.

Contrairement aux travaux précédents, notre projet cherche à s'éloigner des sentiers battus en la matière. En effet, nous avons construit notre propre base de données, ce qui permet de mieux contrôler la qualité et la pertinence des données pour notre problématique spécifique. Notre sujet, la détection et la classification de *Karenia selliformis*, une algue toxique, exige des méthodes adaptées aux caractéristiques de cette espèce particulière. Par ailleurs, il est important de noter qu'aucun des travaux recensés n'a abordé la classification du *Karenia selliformis*, ce qui confère à notre étude un caractère novateur. De plus, l'utilisation de la cytométrie en flux d'imagerie pour collecter les images confère à notre approche un avantage unique, en offrant des données d'une grande richesse morphologique. Ainsi, notre démarche est difficilement comparable aux autres études qui utilisent généralement des bases de données standards et des images issues de méthodes d'imagerie différentes.

Notre choix méthodologique, basé sur l'utilisation de YOLO et des modèles de réseaux de neurones convolutionnels (CNN), repose sur plusieurs justifications. Premièrement, YOLO est un modèle de détection d'objets particulièrement performant en termes de rapidité et de précision, ce qui est essentiel pour la détection en temps réel, surtout lorsqu'il s'agit d'analyser des volumes importants d'images. YOLO est largement utilisé dans la classification d'objets complexes, et ses versions améliorées intègrent des mécanismes d'attention et de meilleures

architectures, renforçant ainsi sa capacité à extraire des caractéristiques essentielles dans des images variées.

D'autre part, les CNN sont connus pour leur performance élevée dans l'analyse d'images, grâce à leur capacité à identifier des motifs complexes tels que ResNet, VGG16, EfficientNet et Inception. En particulier, les CNN se sont montrés robustes dans des tâches de classification où les caractéristiques visuelles sont cruciales, comme c'est le cas pour *Karenia selliformis*. En utilisant une combinaison de YOLO pour la détection rapide et de CNN pour une classification approfondie, nous optimisons notre méthodologie pour répondre efficacement aux exigences de précision et de fiabilité nécessaires pour ce projet.

2.5 Conclusion

En conclusion, ce chapitre a permis d'établir une base solide pour notre étude en présentant d'abord les principes fondamentaux de l'intelligence artificielle et de l'apprentissage automatique, essentiels pour comprendre les méthodes employées dans la détection et la classification d'images. La revue de la littérature scientifique a ensuite permis de mettre en lumière les principales avancées technologiques ainsi que les approches actuelles utilisées pour l'identification et la classification des microalgues. Enfin, la synthèse a mis en évidence les forces et les limitations des différentes approches, notamment en termes de précision et de diversité des bases de données utilisées.

Methodologie et développement du modèle

Sommaire

3.1	Introduction	45
3.2	Architecture globale du projet	45
3.3	Collecte de données	46
3.4	Préparation de données	47
3.4.1	Nettoyage de données	47
3.4.2	Annotation de données	48
3.5	Détection et extraction des cellules	53
3.5.1	Entraînement du modèle	53
3.5.2	Détection des microalgues avec YOLOv8	55
3.5.3	Extraction de boîtes englobantes	56
3.6	Classification des microalgues	57
3.6.1	Apprentissage par transfert	57
3.6.2	Modèles préentraînés/Architecture utilisée	58
3.6.3	Entraînement des modèles	60
3.7	Conclusion	61

3.1 Introduction

Dans ce chapitre, nous présentons l'approche adoptée pour concevoir et développer notre solution de classification de *Karenia selliformis*. Cette démarche comprend plusieurs étapes essentielles, allant de la collecte et du prétraitement des données à l'entraînement d'un modèle de deep learning adapté pour la détection et la classification. Chaque phase a été soigneusement structurée pour garantir l'efficacité et la précision de notre solution, permettant ainsi une identification automatisée et fiable de cette microalgue dans des échantillons complexes.

3.2 Architecture globale du projet

Dans ce projet, nous avons adopté une démarche structurée pour la détection et la classification de *Karenia selliformis*. L'architecture générale de notre méthodologie, représentée dans la figure 3.1, comprend plusieurs étapes essentielles : collecte des données, préparation des images, détection et extraction des cellules, puis classification en deux classes, "*Karenia Selliformis*" et "Autres Cellules". Chaque étape a été élaborée dans le but d'optimiser la précision et de garantir des performances élevées en classification. Nous détaillerons chacune de ces étapes dans les sections suivantes.




FIGURE 3.1 – Architecture globale de la méthodologie

3.3 Collecte de données

Les données utilisées dans ce projet proviennent de l'Institut National des Sciences et Technologies de la Mer. L'ensemble de données comprend 370 prélèvements, effectués toutes les heures sur une période de 9 jours, du 27 septembre au 5 octobre 2019, pendant l'automne. Ces prélèvements ont été réalisés dans le port de commerce de Sfax. Chaque prélèvement contient des images numériques de microalgues marines, capturées par cytométrie en flux d'imagerie et téléchargées via le logiciel CytoClus. Au total, 8800 images de microalgues variées ont été collectées. La figure ci-dessous illustre l'interface du logiciel CytoClus.




FIGURE 3.2 – Le logiciel CytoClus

Ces images présentent une variabilité en termes de taille, de contraste et de qualité en fonction des conditions de prélèvement et de numérisation, ce qui contribue à renforcer la robustesse du modèle face à des données réelles diversifiées.

La figure suivante illustre quelques exemples visuels d'images de microalgues issues de notre ensemble de données.




FIGURE 3.3 – Échantillon des images constituant la base de données

3.4 Préparation de données

3.4.1 Nettoyage de données

Le processus de nettoyage des données (Data Cleaning), étape importante pour garantir la qualité et la pertinence de l'ensemble des données destinées à l'entraînement du modèle. Ce processus inclut l'identification et la suppression des images inexploitable, telles que des cellules partiellement visibles ou présentant une mauvaise qualité d'image. Des vérifications manuelles ont été appliquées afin de sélectionner des images optimales pour l'apprentissage, permettant ainsi de maximiser la précision et la fiabilité du modèle final.

Le processus de nettoyage a inclus les tâches suivantes :

- **Exclusion des images inexploitable** : La détection et la suppression d'images complexes ont fait partie intégrante du processus de nettoyage. Nous avons ainsi éliminé les images contenant des cellules éclatées, partiellement visibles ou peu nettes, rendant leur identification difficile.
- **Filtrage des images de faible qualité** : les images floues ou mal éclairées, réduisant la clarté des structures cellulaires, ont été systématiquement éliminées après validation par un biologiste expert.

- **Suppression des doublons** : les images répétées ont été identifiées et éliminées, garantissant ainsi qu'aucune image ne soit analysée plusieurs fois et assurant l'unicité des données pour un traitement optimal.
- **Validation par un expert biologiste** : chaque décision de suppression d'images a été soumise à l'expertise d'un biologiste, afin de garantir la pertinence biologique des données conservées et leur adéquation pour les analyses ultérieures. Grâce à cette validation experte, seules les images jugées représentatives et fiables ont été retenues, renforçant la qualité des étapes suivantes d'annotation et de détection de *Karenia Selliformis*.

Une fois les données nettoyées et centralisées, l'étape suivante du processus consiste à réaliser l'annotation des images.

3.4.2 Annotation de données


L'annotation des données est une étape indispensable dans le processus de préparation des jeux de données pour les modèles d'apprentissage automatique, notamment en vision par ordinateur. Cette tâche peut être réalisée à l'aide de divers logiciels spécialisés, tels que LabelImg, CVAT, Labelbox et Roboflow. Chacun de ces outils offre des fonctionnalités uniques adaptées à différents besoins d'annotation.

Dans notre cas, nous avons choisi d'utiliser Roboflow en raison de ses nombreuses avantages. Roboflow facilite le chargement et l'organisation des images, tout en permettant une annotation précise et efficace des microalgues. Sa capacité à convertir automatiquement les annotations dans le format requis pour des modèles comme YOLOv8 simplifie considérablement le flux de travail. De plus, Roboflow propose des options d'augmentation des données, ce qui est essentiel pour améliorer la diversité des échantillons et renforcer la performance du modèle. En somme, le choix de Roboflow s'explique par son interface conviviale, ses fonctionnalités d'optimisation et sa compatibilité avec les exigences des projets de classification des microalgues.

- **Processus d'annotation** :

Les cellules ont été annotées manuellement en utilisant la fonctionnalité de boîte englobante (bounding box) de Roboflow. Pour chaque microalgue, une boîte a été soigneusement tracée autour de l'entité identifiée afin de délimiter précisément sa zone. Cette méthode d'annotation permet non seulement de localiser chaque microalgue dans l'image, mais également de fournir des informations pertinentes pour le processus d'entraînement des modèles d'apprentissage automatique. Les annotations ont été organisées en deux catégories distinctes : *Karenia selliformis*, qui représente l'espèce d'intérêt, et Autres cellules, englobant toutes les autres microalgues ou organismes présents. Cette classification par catégories facilite l'analyse des données et assure la distinction efficace du modèle entre *Karenia selliformis* et les autres types de cellules. Ce qui s'avère essentiel pour une identification précise dans le cadre de notre projet.

La figure suivante illustre les différentes classes annotées à l'aide de RoboFlow



The screenshot shows the RoboFlow interface with two classes defined. The 'Classes' tab is active, showing a list of classes with their counts. The 'Autres' class has a count of 4,009 and is represented by a red dot. The 'Karenia' class has a count of 4,005 and is represented by a purple dot. The interface includes buttons for 'What is a class?', 'Lock Classes', '+ Add', and 'Modify Classes'.

COLOR	COUNT ↻	CLASS NAME
	4 009	Autres
	4 005	Karenia

FIGURE 3.4 – Les classes annotées avec RoboFlow

Classe *Karenia Selliformis*

La classe "*Karenia selliformis*" comprend un total de 4 000 images de cette microalgue toxique, avec 4 005 instances de microalgues annotées. Ces images capturées rigoureusement sous divers angles, formes et tailles représentent une large gamme de morphologies, allant des cellules individuelles aux agrégats, ce qui permet de constituer un jeu de données riche et varié. Pour enrichir cette base, nous avons intégré des images provenant d'études en aquaculture réalisées par des biologistes, mettant en évidence les cellules de *Karenia selliformis* en phase d'éclatement. Cette inclusion est essentielle, car elle reflète les conditions réelles rencontrées dans les environnements aquatiques, où les cellules peuvent se présenter sous différentes formes en fonction de leur état physiologique. En intégrant ces exemples diversifiés, nous augmentons la capacité

du modèle à identifier et classer efficacement *Karenia selliformis*, même dans des situations complexes et dynamiques. Par conséquent, on garantit la précision et la fiabilité du processus de classification. La figure 3.5 présente un exemple de *Karenia selliformis* annoté à l'aide de RoboFlow.




FIGURE 3.5 – Exemple du *K.Selliformis* annoté avec Roboflow

Classe Autres Cellules

La classe "Autres" regroupe un total de 3 950 images, représentant une diversité de microalgues. Au total, 4 009 microalgues ont été annotées puisqu'on comptabilise certaines images contenant en effet plusieurs cellules distinctes, y compris celles qui présentent des caractéristiques morphologiques et dimensionnelles similaires à *Karenia selliformis*, ainsi que d'autres microalgues identifiées lors des prélèvements. Cette diversité est essentielle pour entraîner le modèle à reconnaître non seulement les espèces qui pourraient être facilement confondues avec *K. selliformis*, mais aussi à distinguer les différentes microalgues présentes dans l'environnement. En intégrant des images de microalgues similaires et d'autres espèces variées, nous renforçons la capacité du modèle à effectuer des classifications précises et fiables. Cet enrichissement de la classe permet de mieux appréhender la variabilité naturelle des microalgues. De ce fait, on arrive à minimiser les erreurs d'identification et à améliorer l'efficacité du processus de classification. La figure 3.6 présente un exemple d'autres cellules annoté à l'aide de RoboFlow.




FIGURE 3.6 – Exemple d'autres cellules annotées avec Roboflow

- **Validation par les experts en biologie :**

Pour garantir la qualité et la précision des annotations, chaque série a été examinée par trois experts en biologie. Ce processus de validation a exigé une collaboration étroite avec ces spécialistes, qui ont minutieusement revu les annotations afin d'assurer leur exactitude et leur pertinence. Grâce à cette approche rigoureuse, nous avons pu renforcer la fiabilité des données utilisées pour l'entraînement du modèle, ce qui nous a permis d'atteindre des niveaux élevés de précision dans la classification des microalgues.

- **Redimensionnement :**

À l'issue du processus d'annotation, les images sont redimensionnées standardement de 256x256 pixels pour répondre aux spécifications d'entrée du modèle retenu. Ce redimensionnement est effectué afin de conserver la qualité ainsi que les éléments clés des images, comme l'indique la figure suivante.




FIGURE 3.7 – Technique de redimensionnement

- **Division :**

Les images ont été segmentées en trois ensembles distincts : 70 % destinés à l'entraînement, 20 % à la validation et 10 % aux tests, conformément aux pratiques courantes en apprentissage automatique. Cette répartition est illustrée dans la figure ci-dessous.



FIGURE 3.8 – Technique de Division

- **Exportation des données annotées :** Une fois le redimensionnement et la validation des annotations effectués, les données peuvent être exportées dans divers formats, notamment COCO et YOLO. Pour notre projet, nous avons décidé d'opter pour le format YOLO, qui s'avère particulièrement adapté aux spécificités de notre modèle. La figure ci-dessous illustre ce processus.




FIGURE 3.9 – Les types d’exportation des données

3.5 Détection et extraction des cellules

Après avoir préparé les données, annoté les microalgues et exporté les images dans un format compatible, nous procédons à l’utilisation de YOLOv8 pour détecter les cellules dans les images. Cette section détaille le processus d’entraînement du modèle sur les données annotées, ainsi que les étapes de détection et d’extraction des boîtes englobantes des cellules détectées.

3.5.1 Entraînement du modèle

L’entraînement d’un modèle de deep learning est une phase cruciale où le modèle apprend à partir des données d’entraînement pour effectuer des prédictions sur de nouvelles données. Ce processus repose sur plusieurs éléments clés :

- **Données d’entraînement :** Le modèle est initialement exposé à un ensemble de données étiquetées, où chaque image est accompagnée de son annotation correcte. Grâce à ces données, le modèle ajuste ses poids internes afin de minimiser l’écart entre ses prédictions

et les étiquettes réelles, optimisant ainsi sa capacité à détecter les cellules de manière autonome.

- **Fonction de perte (Loss Function) :** La fonction de perte mesure l'écart entre la prédiction du modèle et la vérité terrain. L'entraînement vise à minimiser cette perte, ce qui implique d'ajuster les poids du modèle pour améliorer ses prédictions. Les optimisateurs, comme Adam ou le gradient stochastique (SGD), sont essentiels pour diriger ces ajustements de manière efficace et rapide, favorisant ainsi une convergence plus rapide vers un modèle précis et fiable.
- **Époques (Epochs) :** Une époque représente un passage complet à travers l'ensemble des données d'entraînement. Le nombre total d'époques détermine combien de fois le modèle examinera chaque exemple de l'ensemble des données. Choisir un nombre approprié d'époques est crucial pour garantir un apprentissage efficace, en permettant au modèle de s'améliorer tout en évitant le surapprentissage (overfitting). Un équilibre doit donc être trouvé pour optimiser les performances sans compromettre la généralisation du modèle.
- **Taux d'apprentissage (Learning Rate) :** Le taux d'apprentissage contrôle la vitesse à laquelle le modèle ajuste ses poids en réponse à l'erreur mesurée par la fonction de perte. Un taux d'apprentissage approprié est crucial pour assurer la convergence du modèle vers un point optimal sans oscillations ni stagnation.
- **Dropout :** Le dropout est une technique de régularisation utilisée pour prévenir le surapprentissage en désactivant aléatoirement un pourcentage de neurones pendant l'entraînement. Cela empêche le modèle de devenir trop dépendant de certains neurones, améliorant ainsi sa capacité de généralisation sur des données non vues.

Après avoir introduit ces concepts fondamentaux, nous avons appliqué YOLOv8 pour détecter les cellules dans les images issues du cytomètre. YOLOv8 est un modèle de détection d'objets en temps réel, capable d'analyser des images complexes avec une rapidité et une précision remarquables. Ce modèle se décline en plusieurs variantes (nano, small, medium, large, xlarge), chacune présentant un compromis distinct entre vitesse d'exécution et précision de détection, comme le montre la figure ci-dessous.

Model	size (pixels)	mAP ^{val} 50-95	Speed CPU ONNX (ms)	Speed A100 TensorRT (ms)	params (M)	FLOPs (B)
YOLOv8n	640	18.4	142.4	1.21	3.5	10.5
YOLOv8s	640	27.7	183.1	1.40	11.4	29.7
YOLOv8m	640	33.6	408.5	2.26	26.2	80.6
YOLOv8l	640	34.9	596.9	2.43	44.1	167.4
YOLOv8x	640	36.3	860.6	3.56	68.7	260.6

FIGURE 3.10 – Les tailles de YOLOv8

Pour notre projet, nous avons choisi la variante YOLOv8-m (medium), qui offre un bon compromis entre la capacité de détection et la vitesse d'inférence.

Paramètres d'entraînement initiaux :

Pour l'entraînement initial, nous avons configuré le modèle avec des paramètres standards, tels que le nombre d'époques, la taille de batch et le taux d'apprentissage, tout en utilisant l'optimiseur AdamW. Ces paramètres ont été définis afin de permettre une première évaluation des performances du modèle. Les ajustements de ces paramètres et leurs impacts sur les performances seront détaillés dans le chapitre suivant, lors de l'évaluation du modèle.

```
results = model.train(data=yaml_file_path, epochs=100, batch=32, lr=0.0005,
                      optimizer='AdamW', seed=0)
```

FIGURE 3.11 – Entraînement du modèle

3.5.2 Détection des microalgues avec YOLOv8

Après l'entraînement du modèle, nous avons appliqué YOLOv8 pour détecter les microalgues dans notre ensemble d'images acquises par cytométrie en flux. Cette étape consiste à passer chaque image à travers le modèle, qui analyse les caractéristiques visuelles et identifie les régions contenant des microalgues. Pour chaque microalgue détectée, le modèle dessine une boîte englobante (bounding box) autour de la structure, permettant ainsi de localiser précisément chaque microalgue dans l'image. Ce processus permet non seulement d'identifier la présence des microalgues, mais aussi de les localiser avec une grande précision, facilitant leur

extraction et classification pour des analyses ultérieures. Ce type de détection est essentiel pour automatiser le processus d'identification des microalgues et accélérer les tâches de surveillance dans les écosystèmes aquatiques. La figure suivante présente un exemple visuel des résultats de détection, montrant les cellules entourées par des boîtes englobantes.




FIGURE 3.12 – Exemple de détection de cellules

3.5.3 Extraction de boîtes englobantes

Une fois les microalgues détectées, les boîtes englobantes sont extraites pour isoler ces régions d'intérêt. Chaque boîte englobante correspond à une microalgaue identifiée par le modèle. Cette étape d'extraction permet de créer un nouvel ensemble de données constitué exclusivement des microalgues détectées, facilitant ainsi leur analyse plus approfondie. En isolant ces régions spécifiques, nous pouvons appliquer des techniques supplémentaires, telles que la classification, pour identifier les différentes espèces de microalgues ou analyser leurs caractéristiques morphologiques. Cela permet également d'améliorer la précision des résultats en se concentrant uniquement sur les zones pertinentes de l'image.

La figure ci-dessous illustre des exemples de cellules extraits à partir des boîtes englobantes détectées.




FIGURE 3.13 – Exemple de cellules extraites

3.6 Classification des microalgues

La classification des microalgues représente une étape cruciale dans notre démarche, car elle permet de distinguer les microalgues détectées en plusieurs classes, telles que "Karenia" et "Autres". Ce processus de catégorisation est fondamental pour extraire des informations biologiques clés qui peuvent avoir un impact direct sur l'écosystème marin. L'objectif de cette phase est de concevoir un modèle capable de généraliser efficacement et d'assurer une classification précise des cellules, contribuant ainsi à une meilleure compréhension et gestion de la dynamique des microalgues, en particulier celles potentiellement toxiques.

3.6.1 Apprentissage par transfert

Le transfert d'apprentissage est une technique puissante en apprentissage automatique, qui permet de réutiliser les connaissances qu'un modèle a acquises en s'entraînant sur une tâche de référence pour améliorer ses performances sur une tâche similaire. Cette approche est particulièrement utile lorsque les données spécifiques à la nouvelle tâche sont limitées, car elle permet d'intégrer des caractéristiques et des informations générales issues de vastes bases de données. Dans notre projet, le transfert d'apprentissage est une approche clé pour maximiser les performances de classification des microalgues malgré un volume restreint de données d'entraînement. Nous avons ainsi opté pour des modèles préentraînés, tels que ceux formés sur

de grands ensembles de données, qui sont capables de capturer des caractéristiques visuelles générales, notamment les formes, textures et structures. En ajustant les couches finales de ces modèles pour la détection et la classification spécifiques aux microalgues, nous profitons de cette base de connaissances générale. Cela renforce la précision du modèle tout en diminuant le besoin d'un grand volume de données d'entraînement dédiées à notre problématique.

Les Avantages des modèles préentraînés :

- **Gain de temps et de ressources** : L'entraînement d'un modèle de grande envergure depuis zéro exige une quantité importante de données et de puissance de calcul. En réutilisant un modèle préentraîné, on profite des ressources déjà investies dans l'entraînement initial, ce qui accélère considérablement le processus.
- **Amélioration des performances** : Les modèles préentraînés ont déjà appris des caractéristiques visuelles de base (bords, textures, formes) sur des millions d'images, ce qui peut aider à mieux distinguer des détails fins dans les images de microalgues.
- **Réduction du risque de surapprentissage** : Grâce aux connaissances déjà intégrées, un modèle préentraîné commence son entraînement sur une base plus solide, ce qui diminue le risque de surapprentissage ou de biais sur des petits ensembles de données. Cela renforce la robustesse et la fiabilité du modèle pour des applications réelles.

3.6.2 Modèles préentraînés/Architecture utilisée

Pour cette tâche, nous avons sélectionné plusieurs modèles préentraînés pour l'expérimentation, notamment :

- **VGG16**
- **EfficientNetB0**
- **ResNet-50**
- **InceptionV3**

Ces modèles ont été choisis pour leur robustesse et leur performance éprouvée dans la classification d'images, ainsi que pour leur capacité à être facilement adaptés à notre projet.

Pour chaque modèle préentraîné, l'architecture de base a été conservée comme backbone pour l'extraction des caractéristiques. Des couches supplémentaires ont été ajoutées pour adapter le modèle à la classification spécifique des microalgues. Voici les éléments clés de l'architecture utilisée :

- **Base Model** : Le modèle préentraîné sert de fondation pour l'extraction des caractéristiques importantes à partir des images. Afin de tirer pleinement parti des connaissances acquises lors du préentraînement sur des ensembles de données volumineux, les couches du modèle de base ont été gelées. Cela signifie que les poids de ces couches ne seront pas modifiés pendant l'entraînement (`layer.trainable = False`). Cette approche permet de préserver les caractéristiques générales apprises par le modèle et de concentrer l'apprentissage sur les nouvelles couches ajoutées.
- **Couches Ajoutées** :
 - **GlobalAveragePooling2D** : Cette couche permet de réduire les dimensions des caractéristiques extraites par le modèle de base, en prenant la moyenne de chaque caractéristique sur toute l'image, ce qui prépare les données pour les couches de classification finales.
 - **Couches de Dropout** : Des couches de dropout ont été intégrées pour prévenir le surapprentissage.
 - **Couches Fully Connected (Dense Layers)** : Ces couches entièrement connectées permettent de combiner les caractéristiques réduites et de préparer la sortie pour la classification finale.
 - **Sigmoid Layer** : La dernière couche, une couche d'activation Sigmoid, convertit la sortie du modèle en une probabilité comprise entre 0 et 1. Cette probabilité est ensuite utilisée pour classer les microalgues en deux catégories : *Karenia* (si la probabilité dépasse un certain seuil, généralement 0,5) ou autres.

La figure suivante illustre la structure du modèle utilisé pour l'apprentissage par transfert dans notre projet, montrant comment le modèle de base préentraîné est combiné avec des couches ajoutées pour la classification des microalgues.




FIGURE 3.14 – Structure des modèles pour l'apprentissage par transfert

Après avoir décrit les couches ajoutées pour la classification des microalgues et précisé le modèle préentraîné utilisé comme base, nous abordons désormais la phase d'entraînement des modèles. Cette étape est essentielle pour ajuster les modèles préentraînés aux particularités de notre tâche, en affinant leur capacité à différencier le *Karenia* des autres microalgues.

3.6.3 Entraînement des modèles

Pour cette phase, nous avons suivi un processus rigoureux qui comprend plusieurs étapes, depuis l'initialisation des modèles jusqu'à l'évaluation de leurs performances pendant l'entraînement. **Étapes de l'entraînement :**

1. **Initialisation des modèles :** Les modèles ont été initialisés avec des poids préentraînés, à l'exception des nouvelles couches ajoutées, qui ont été initialisées aléatoirement. Cette approche permet au modèle de commencer avec une base solide tout en s'adaptant à la nouvelle tâche.
2. **Phase d'entraînement :** Les modèles ont été entraînés sur plusieurs époques, ajustant leurs poids à chaque itération pour minimiser l'erreur entre les prédictions et les étiquettes réelles. Cette phase vise à optimiser les performances du modèle sur l'ensemble d'entraînement tout en ajustant les paramètres pour capturer les nuances spécifiques des microalgues.
3. **Surveillance continue :** Tout au long de l'entraînement, des métriques d'évaluation, telles que la précision (accuracy) et l'erreur (loss), ont été suivies pour surveiller les

progrès des modèles. Le modèle ayant la plus petite valeur de loss a été sauvegardé comme le meilleur modèle, ce qui a permis d'optimiser la performance sur la tâche de classification des microalgues.

L'entraînement des modèles représente une étape clé dans le développement du système de classification des microalgues. Après avoir intégré de nouvelles couches adaptées à notre tâche, les modèles préentraînés sont prêts à être évalués et optimisés afin de maximiser leur performance dans la détection et la classification du *Karenia* et des autres microalgues.

3.7 Conclusion

Ce chapitre détaille la méthodologie mise en place pour la détection et la classification des microalgues à l'aide de modèles d'apprentissage profond. Nous avons couvert les différentes étapes, depuis la collecte et l'organisation des données jusqu'à l'entraînement des modèles, en passant par l'application de techniques d'optimisation et de transfert d'apprentissage, ainsi que l'utilisation de modèles préentraînés. Le chapitre suivant se concentrera sur l'évaluation des performances des modèles et sur les résultats obtenus.

Résultats expérimentaux et synthèse

Sommaire

4.1	Introduction	63
4.2	Environnement matériel et logiciel	63
4.2.1	Environnement matériel	63
4.2.2	Environnement logiciel	64
4.3	Mesures d'évaluation	66
4.4	Résultats expérimentaux	69
4.4.1	Résultats du modèle de détection (YOLOv8)	69
4.4.2	Résultats des modèles de classification	72
4.4.3	Evaluation des résultats	77
4.5	Synthèse de l'Approche	78
4.6	Transition vers l'intégration des modèles	79
4.6.1	Présentation de l'application web	79
4.6.2	Aspects techniques	79
4.6.3	Interface utilisateur et fonctionnalités	82
4.7	Conclusion	85

4.1 Introduction

Dans ce chapitre consacré à la mise en œuvre et aux résultats, nous présentons un aperçu complet de l'environnement de développement, des outils et des bibliothèques utilisés pour nos expérimentations, ainsi que des métriques de performance adoptées pour évaluer l'efficacité des modèles en expliquant le choix de chaque métrique et leur pertinence pour notre étude. Enfin, nous procédons à une analyse approfondie des résultats obtenus avec les différents modèles testés.

4.2 Environnement matériel et logiciel

Ce projet a nécessité un environnement technique soigneusement défini pour garantir des performances optimales, notamment durant l'entraînement des modèles et le traitement des images. L'infrastructure matérielle et logicielle, ajustée aux exigences spécifiques du projet, a permis de faire fonctionner efficacement les modèles d'intelligence artificielle tout en assurant un traitement précis des images de microalgues. Le choix d'un matériel performant et d'outils logiciels appropriés s'est donc révélé crucial pour le bon déroulement et la réussite des différentes étapes du projet.

4.2.1 Environnement matériel

Pour réaliser ce projet, nous avons utilisé un ordinateur portable de marque ASUS. Le tableau ci-dessous présente ses caractéristiques.

Caractéristiques	Détails
Processeurs	Intel(R) Core(TM) i7-12700H
Fréquence	2.30 GHz
RAM	8,00 Go
Disque Dur	1TO
Système d'exploitation	Windows 11 64Bits

4.2.2 Environnement logiciel

Cette section présente les différentes technologies et outils logiciels utilisés pour la réalisation de ce projet.

- **Roboflow** : est une plate-forme de vision par ordinateur qui permet aux utilisateurs de créer des modèles de vision par ordinateur plus rapidement et avec plus de précision grâce à de meilleures techniques de collecte de données, de prétraitement et de formation de modèles. Roboflow permet aux utilisateurs de télécharger des ensembles de données personnalisés, de dessiner des annotations, de modifier les orientations des images, de redimensionner les images, de modifier le contraste des images et d'effectuer une augmentation des données. Il peut également être utilisé pour former des modèles [41].



FIGURE 4.1 – Logo de Roboflow

- **Google Colab** : Google Colab ou Colaboratory est un service cloud, offert par Google (gratuit), basé sur Jupyter Notebook et destiné à la formation et à la recherche dans l'apprentissage automatique. Cette plateforme permet d'entraîner des modèles de Machine Learning directement dans le cloud. Sans donc avoir besoin d'installer quoi que ce soit sur notre ordinateur à l'exception d'un navigateur.[42]



FIGURE 4.2 – Logo de Google Colab

- **Python** : un langage de programmation polyvalent et facile à apprendre, apprécié pour sa syntaxe claire et concise. Il offre une vaste gamme de bibliothèques et de frameworks qui facilitent le développement d'applications, l'analyse de données, l'intelligence artificielle,

l'apprentissage automatique et bien plus encore. Python est largement utilisé dans l'industrie et la recherche en raison de sa flexibilité, de sa lisibilité et de sa vaste communauté de développeurs. Avec sa simplicité et sa puissance, Python est devenu un langage de choix pour les programmeurs débutants et expérimentés.[43]



FIGURE 4.3 – Logo de Python

- **TensorFlow** : est une bibliothèque open-source développée par Google pour le calcul numérique et l'apprentissage automatique. Elle permet aux développeurs de créer et d'entraîner des modèles de machine learning à grande échelle, en particulier des réseaux de neurones profonds.[44]



FIGURE 4.4 – Logo de TensorFlow

- **NumPy** : est une bibliothèque essentielle du langage Python, conçue pour manipuler efficacement des tableaux et matrices multidimensionnels, ainsi que pour exécuter des opérations mathématiques avancées sur ces structures. Cette bibliothèque libre et open source propose de nombreuses fonctionnalités permettant, entre autres, de créer des tableaux à partir de fichiers, de sauvegarder des tableaux, et de manipuler des vecteurs, matrices, et polynômes. NumPy constitue également le socle de SciPy, un ensemble de bibliothèques Python dédié au calcul scientifique.[45]



FIGURE 4.5 – Logo de Numpy

- **PyTorch** : est une bibliothèque Python open source dédiée à l'apprentissage automatique, conçue à partir de la plateforme Torch développée par Meta. Administrée par la PyTorch Foundation, elle permet d'effectuer des calculs tensoriels essentiels pour le deep learning. Ces calculs sont optimisés pour être exécutés soit sur le processeur (CPU) soit, si compatible, sur un processeur graphique (GPU) via CUDA pour de meilleures performances.[46]




FIGURE 4.6 – Logo de PyTorch

4.3 Mesures d'évaluation

Les mesures d'évaluation sont essentielles pour comparer les performances des modèles de détection et de classification. Certaines, comme la précision, le rappel et la F1-score, sont communes aux deux tâches, tandis que d'autres sont spécifiques. Par exemple, dans la détection, on utilise des mesures comme le score IoU pour évaluer les boîtes englobantes, tandis que dans la classification, on privilégie des outils comme la matrice de confusion. Ces mesures aident à analyser les forces et les faiblesses du modèle.

1. **Matrice de confusion** : Une matrice de confusion est utilisée dans les deux tâches pour visualiser les performances globales du modèle. Elle montre la répartition des prédictions correctes et incorrectes en termes de vrais positifs (VP), faux positifs (FP), faux négatifs (FN), et vrais négatifs (VN). Que ce soit pour la détection ou pour la classification, la matrice de confusion fournit une représentation visuelle claire des erreurs et des réussites du modèle. La figure suivante montre une représentation de la forme du matrice :

Predicted Class	True Class		
		P	N
	P	TP	FP
	N	FN	TN

FIGURE 4.7 – Matrice de confusion générale [47]

Cette matrice de confusion est divisée en quatre zones principales :

- **TP (True Positive / Vrais Positifs)** : Représente les instances où le modèle a correctement détecté ou classifié l'objet. Dans le cadre de la détection, cela correspond à des microalgues bien détectés, tandis que pour la classification, cela correspond à des microalgues correctement classés (*Karenia Selliformis* ou Autres).
- **FP (False Positive / Faux Positifs)** : Cette partie représente les instances où le modèle a détecté ou classé un objet alors que celui-ci ne correspond pas à la réalité. Dans le cas de la détection, il s'agit de fausses détections (faux cellules détectés). Pour la classification, ce sont des microalgues mal classés.
- **FN (False Negative / Faux Négatifs)** : Représente les objets que le modèle n'a pas détectés ou mal classifiés. Pour la détection, il s'agit des microalgues non détectés, et pour la classification, ce sont des microalgues *Karenia* classés comme autres cellules (et inversement).
- **TN (True Negative / Vrais Négatifs)** : Correspond aux cas correctement rejetés par le modèle. Cela signifie que le modèle n'a pas détecté ou classé un objet. là où il n'y en avait pas, ce qui constitue un bon résultat.

2. **Précision (Precision)** : La proportion des détections ou des prédictions correctes parmi toutes les détections ou prédictions effectuées. Elle indique la capacité du modèle à éviter les fausses détections ou fausses classifications. La précision se calcule à l'aide de la formule suivante :

$$\text{Précision} = \frac{\text{Vrais Positifs}}{\text{Vrais Positifs} + \text{Faux Positifs}}$$

3. **Rappel (Recall)** : La proportion des objets ou des classes réellement pertinents qui ont été détectés ou classifiés correctement. Le rappel évalue la capacité du modèle à ne pas manquer d'objets importants dans les deux contextes. Le rappel est donné par la formule suivante :

$$\text{Rappel} = \frac{\text{Vrais Positifs}}{\text{Vrais Positifs} + \text{Faux Négatifs}}$$

4. **F1-score** : C'est une moyenne harmonique de la précision et du rappel. Le F1-score est particulièrement utile lorsque les classes sont déséquilibrées, car il permet d'évaluer le compromis entre précision et rappel. Une mesure F1 proche de 1 indique un équilibre parfait entre la précision et le rappel, qui sont inversement liés. L'équation suivante est utilisée pour calculer cette mesure :

$$\text{F1_mesure} = 2 * \frac{\text{Précision} * \text{Rappel}}{\text{Précision} + \text{Rappel}}$$

5. **Précision globale (Accuracy)** : C'est la proportion des prédictions correctes parmi toutes les prédictions faites par le modèle de classification.
6. **Intersection over Union (IoU)** : L'IoU est une métrique qui mesure le degré de chevauchement entre la boîte prédite par le modèle et la boîte réelle (vérité terrain). Il s'agit d'une valeur comprise entre 0 et 1, où un IoU de 1 signifie une correspondance parfaite. Les seuils d'IoU sont utilisés pour déterminer si une prédiction est correcte. Afin de mieux comprendre comment l'IoU est calculé et comment les différents seuils influencent la qualité des détections, la figure suivante illustre plusieurs exemples d'IoU à différents seuils :




FIGURE 4.8 – Illustration de l'IoU à différents seuils [48]

- **IoU < 0.50** : Mauvaise détection (faible chevauchement entre la boîte prédite et la boîte réelle).
- **IoU >= 0.50** : Bonne détection (chevauchement suffisant pour considérer la prédiction comme correcte).

L'IoU est utilisé comme seuil pour décider si une prédiction est correcte ou non. Une fois ce seuil défini, la qualité globale des détections est mesurée par la Mean Average Precision (mAP).

7. **Mean Average Precision (mAP)** : La mAP est la moyenne des précisions calculées à différents seuils d'IoU. Elle évalue la capacité du modèle à détecter correctement les objets (glomérules) dans une image. Deux variantes sont couramment utilisées :

- **mAP@0.50** : La précision moyenne pour un seuil IoU de 0.5. Une détection est considérée correcte si l'IoU est supérieur ou égal à 0.5.
- **mAP@0.5 :0.95** : La moyenne des mAPs pour des seuils d'IoU allant de 0.5 à 0.95 avec un pas de 0.05. Ce critère est plus strict et mesure la capacité du modèle à bien localiser les objets avec précision.

4.4 Résultats expérimentaux

4.4.1 Résultats du modèle de détection (YOLOv8)

Le modèle YOLOv8 a été utilisé pour détecter les microalgues dans les images de cytométrie en flux. Cette section présente les résultats de détection, ainsi que les ajustements des paramètres effectués pour optimiser la performance du modèle.

4.4.1.1 Ajustements des paramètres pour la détection

L'optimisation des paramètres du modèle YOLOv8 a été une étape cruciale pour obtenir des performances optimales dans la détection des microalgues. Compte tenu de l'objectif de maximiser la détection tout en réduisant les fausses détections, plusieurs ajustements

ont été effectués. Tout d'abord, l'optimiseur AdamW a été choisi pour sa capacité à gérer efficacement les poids, intégrant une régularisation par décroissance des poids (Weight Decay) afin de prévenir le surapprentissage. Différents taux d'apprentissage ont ensuite été testés, en commençant par des valeurs faibles pour éviter une convergence prématurée vers un minimum local non optimal, stabilisant ainsi la convergence du modèle.

La taille du batch a également été ajustée. Après plusieurs essais, un batch de 32 s'est révélé être un compromis satisfaisant entre la rapidité d'apprentissage et la précision, tout en tenant compte des limitations du jeu de données. Concernant les époques d'entraînement, des évaluations ont été menées à 10, 50, 60 et 100 époques, montrant qu'après 50 époques, le modèle atteignait une convergence stable avec un bon équilibre entre précision et rappel.

Enfin, le seuil de confiance, paramètre clé influençant directement la qualité de la détection, a été testé à plusieurs niveaux. Un seuil de 0,7 s'est avéré être le plus efficace, permettant de maximiser la détection des microalgues tout en réduisant les fausses détections, atteignant ainsi notre objectif de minimisation des erreurs de classification.

4.4.1.2 Évaluation des performances et sélection du modèle optimal

Après avoir ajusté les paramètres critiques du modèle YOLOv8, nous avons évalué ses performances sur les ensembles de test en utilisant les métriques suivantes : précision et rappel. Ces métriques permettent de juger la capacité du modèle à détecter les microalgues avec précision, tout en minimisant les fausses détections.

le tableau ci-dessous montre les résultats des métriques de test pour différentes époques

Résultats sur l'ensemble de test

Époque	Précision	Rappel
10	0,9	0,72
50	0,89	0,9
60	0,85	0,87
100	0,94	0,91

Les performances sur l'ensemble de test montrent une amélioration continue à mesure que le nombre d'époques augmente. Après 100 époques, le modèle atteint un équilibre intéressant

avec une précision de 0,94 et un rappel de 0,91, témoignant d’une détection stable et cohérente. L’amélioration marginale observée au-delà de cette étape suggère que prolonger l’entraînement risquerait de conduire à un surajustement.

Matrice de confusion

La matrice de confusion ci-dessous illustre les performances du modèle à l’époque 100, offrant une vue détaillée de la répartition des prédictions correctes et incorrectes sur l’ensemble de test. Comme le montre cette matrice, le modèle parvient à détecter correctement la majorité des microalgues, avec un nombre relativement faible de fausses détections. Cela témoigne de la robustesse du modèle dans sa capacité à identifier les microalgues, tout en minimisant les erreurs de classification, ce qui renforce sa fiabilité pour cette tâche spécifique de détection.




FIGURE 4.9 – Matrice de confusion pour YOLOv8

Cette matrice de confusion présente les performances de classification d’un modèle testé sur un ensemble de 804 images réparties en deux classes : “Karenia” (395 images) et “Autres”

(409 images). Le modèle a correctement prédit 372 images de “Karenia” et 353 images de “Autres”. Cependant, des erreurs subsistent, avec 44 images de “Karenia” classées à tort comme “Autres” et 21 comme “background”. De même, pour la classe “Autres”, 21 images ont été incorrectement classées comme “Karenia” et 30 comme “background”. Ces résultats montrent une bonne précision générale, bien que certaines confusions entre les classes subsistent, notamment entre “Karenia” et “Autres”.

4.4.2 Résultats des modèles de classification

Dans cette section, nous comparons les performances des modèles préentraînés sur l’ensemble de test afin d’évaluer leur capacité à classer les microalgues en Karenia ou autres. Les modèles évalués incluent VGG16, EfficientNetB0, ResNet-50, et InceptionV3. Le critère de comparaison est basé sur les performances obtenues sur l’ensemble de test, notamment la précision, le rappel, et le F1-score.

4.4.2.1 Ajustements des paramètres pour la classification

Pour optimiser les modèles préentraînés (VGG16, EfficientNetB0, ResNet-50, InceptionV3), nous avons ajusté plusieurs paramètres afin d’obtenir les meilleures performances possibles. Tout d’abord, les couches supplémentaires incluaient une couche GlobalAveragePooling2D pour réduire la dimensionnalité des sorties du modèle de base. Nous avons également ajouté une couche dense de 128 unités avec activation ReLU pour capturer les caractéristiques des microalgues, et des couches de Dropout avec des taux ajustés à 30%, afin de limiter le surapprentissage. Les paramètres de l’entraînement ont également été modifiés pour affiner les performances du modèle. Nous avons ajusté la taille du batch ainsi que le nombre d’époques à chaque phase d’expérimentation, afin de trouver la meilleure combinaison pour assurer une convergence optimale. De même, le nombre de neurones dans la couche dense ajoutée a été modifié à plusieurs reprises pour maximiser l’apprentissage du modèle sans augmenter la complexité inutilement. Le taux de Dropout a également été ajusté, afin de trouver l’équilibre parfait entre généralisation et précision.

Le modèle a été entraîné avec l'optimiseur Adam avec un taux d'apprentissage initial fixé à 0.0001, permettant des ajustements progressifs des poids sans risquer une convergence trop rapide. De plus, nous avons utilisé plusieurs callbacks pour surveiller l'entraînement et ajuster le modèle en temps réel. ModelCheckpoint a permis de sauvegarder le modèle présentant la meilleure perte sur l'ensemble de validation, tandis que ReduceLROnPlateau a réduit le taux d'apprentissage lorsque les performances stagnaient. Enfin, le EarlyStopping a été utilisé pour interrompre l'entraînement dès que la performance ne s'améliorait plus, avec une patience de 10 époques, garantissant ainsi de ne pas surentraîner le modèle.

4.4.2.2 Comparaison des modèles sur l'ensemble de test

Les performances des modèles sont évaluées à travers plusieurs époques, et les résultats finaux sont présentés dans le tableau ci-dessous, montrant la précision, le rappel, le F1-score et l'exactitude obtenus sur l'ensemble de test.

Modèle	Epoch	TestAccuracy	Précision	Rappel	F1-score
VGG16	100	0,90	0,91	0,91	0,91
EfficientNetB0	100	0,73	0,82	0,73	0,71
ResNet-50	50	0,93	0,93	0,93	0,93
InceptionV3	50	0,92	0,93	0,93	0,93

Les résultats montrent que ResNet-50 atteint les meilleures performances à l'époque 35, avec une précision, un rappel et un F1-score de 0.93 sur l'ensemble de test. Bien que d'autres modèles comme VGG16 et InceptionV3 atteignent également de bons résultats, ResNet-50 se démarque par sa capacité à maintenir un équilibre optimal entre ces métriques à une époque plus précoce.

Nous avons entraîné le modèle ResNet50 sur un maximum de 50 époques, mais l'entraînement s'est interrompu automatiquement à l'époque 35. Cette interruption s'explique par l'absence d'amélioration du val_loss (perte de validation) au-delà de 0,16707, indiquant que le modèle avait atteint un plateau dans ses performances sur les données de validation. En utilisant une stratégie de early stopping, cette approche permet d'éviter le surapprentissage et de réduire le risque de surajustement, en arrêtant l'entraînement lorsque le modèle ne montre plus de gains significatifs en précision.

• Analyse des Courbes de Perte et d'Accuracy (Resnet50)




FIGURE 4.10 – Courbes de Perte d'Entraînement et de Validation

La courbe de perte pour le modèle ResNet50 montre une évolution positive tout au long des époques. La perte d'entraînement, représentée par la ligne bleue, et la perte de validation, représentée par la ligne orange, diminuent progressivement, indiquant que le modèle apprend efficacement à chaque itération. Vers la fin de l'entraînement, les deux courbes se stabilisent autour de valeurs faibles, entre 0,15 et 0,2, ce qui suggère que le modèle atteint une bonne convergence. De plus, l'absence d'un écart significatif entre la perte d'entraînement et celle de validation indique un bon comportement du modèle sans signe de surapprentissage. En effet, la perte de validation ne montre pas d'augmentation notable par rapport à la perte d'entraînement, ce qui confirme que le modèle généralise bien sur les données de validation. Ainsi, le modèle ResNet50 semble bien adapté aux données, fournissant une performance stable et cohérente.




FIGURE 4.11 – Courbes d'accuracy d'entraînement et de validation

Ce graphique montre l'évolution de la précision de l'entraînement et de la validation d'un modèle ResNet50 au fil de 35 époques. On observe d'abord une augmentation rapide de la précision pour les deux courbes durant les premières époques, signe que le modèle apprend efficacement. Vers l'époque 10, les deux courbes commencent à converger autour de 92% de précision, ce qui indique une bonne généralisation sur l'ensemble de validation. Par la suite, les précisions restent relativement stables, avec de légères fluctuations. La précision d'entraînement atteint environ 94%, tandis que celle de validation se stabilise autour de 92-93%. La légère différence entre ces deux précisions vers la fin des époques suggère un léger surapprentissage, le modèle ayant un peu mieux mémorisé les données.

d'entraînement que celles de validation. En résumé, le modèle ResNet50 présente une bonne performance avec une précision élevée et un surapprentissage minimal.

Cependant, grâce à l'utilisation du ModelCheckpoint, le modèle sauvegardé et utilisé pour l'évaluation finale est celui qui présente les meilleures performances sur l'ensemble de validation (meilleure perte de validation), indépendamment de la continuation de l'entraînement. Cela permet de prévenir l'impact du surapprentissage observé dans les dernières époques, en garantissant que le modèle sélectionné est celui qui généralise le mieux sur les données non vues.

- **Matrice de confusion et rapport de classification**




FIGURE 4.12 – Résultat du modèle ResNet50

Le modèle atteint une précision globale de 93% avec une perte de 0,1493, témoignant de sa capacité à bien distinguer les classes. Pour la classe "Autres", le modèle affiche une précision de 96% et un rappel de 90%, tandis que pour la classe "Karenia", il obtient une précision de 90% et un rappel de 96%. La matrice de confusion montre que le modèle a correctement classé 368 images comme "Autres" et 380 comme "Karenia", avec quelques erreurs de classification : 41 images "Autres" ont été prédites comme "Karenia", et 15 images "Karenia" ont été prédites comme "Autres". Dans l'ensemble, le modèle identifie

bien les deux classes, bien qu'il présente une légère tendance à confondre certaines images de la classe "Autres" avec celles de la classe "Karenia".

- **Classification des images de test**

La figure ci-dessous illustre les résultats de classification obtenus par le modèle ResNet-50 sur l'ensemble de test. Dans cette représentation, la colonne intitulée True correspond à la classe réelle de chaque image, tandis que la colonne Pred indique la classe prédite par le modèle. À chaque prédiction est associée une précision, qui représente le niveau de confiance du modèle pour cette classification. Cette visualisation permet d'observer en détail les performances du modèle, en identifiant les images correctement classées ainsi que celles où des erreurs peuvent survenir.




FIGURE 4.13 – Classification des images par ResNet50

4.4.3 Evaluation des résultats

La multiplication rapide de *Karenia Selliformis*, une microalgue capable de proliférer massivement, peut engendrer des épisodes de blooms algaux, avec des conséquences significatives sur l'écosystème marin, notamment la dégradation de la qualité de l'eau et des

risques pour la faune aquatique. Pour prévenir ces impacts, il est essentiel d'évaluer la densité de *Karenia* dans les échantillons observés.

Dans ce cadre, nous avons calculé le nombre de cellules de *Karenia* détectées dans les images de cytométrie en flux, comme illustré dans la figure ci-dessous. En comparant le nombre de *Karenia* aux autres microalgues présentes. Notre méthode de classification fournit des données quantitatives précieuses aux biologistes, leur permettant d'identifier les situations à risque et de prendre, si nécessaire, des mesures de gestion adaptées pour limiter les effets écotoxiques des blooms.

Nombre d'images prédites pour la classe 'Autres': 383 (47.64%)
Nombre d'images prédites pour la classe 'Karenia': 421 (52.36%)

FIGURE 4.14 – Résultats de classification

4.5 Synthèse de l'Approche

Ce travail s'inscrit dans un projet de recherche de l'INSTM, visant à développer une solution pour la détection et la classification de *Karenia selliformis* en utilisant des techniques d'intelligence artificielle. Ce projet, actuellement en cours, sera finalisé dans le cadre de la thèse, apportant une contribution à la surveillance des écosystèmes marins et à la gestion des risques associés aux microalgues toxiques. Il intègre la biologie et l'informatique pour résoudre des problématiques environnementales. L'utilisation de modèles d'intelligence artificielle, comme YOLOv8 pour la détection et ResNet50 pour la classification, a permis de mettre en place une approche pour identifier cette microalgue. Grâce à une collaboration étroite avec les biologistes, nous avons approfondi les enjeux écologiques liés aux blooms de microalgues, dans une perspective de gestion environnementale. Les résultats obtenus ont montré des performances satisfaisantes. Cependant, l'étude souligne la nécessité d'optimiser les modèles en enrichissant les jeux de données et en ajustant les hyperparamètres afin d'améliorer la précision et la robustesse du système. Ces démarches ouvrent la voie à des améliorations futures dans la détection et la classification des microalgues toxiques.

4.6 Transition vers l'intégration des modèles

Après avoir évalué les performances des modèles de détection et de classification des microalgues toxiques, leur adaptation à une utilisation pratique devient une étape essentielle. Ces modèles seront intégrés dans une application web interactive, offrant aux utilisateurs la possibilité d'analyser efficacement les données issues de la cytométrie en flux d'imagerie et d'obtenir des résultats de manière rapide et précise. Cette initiative vise à démocratiser l'accès à ces technologies pour les chercheurs et les biologistes, tout en renforçant la surveillance et la préservation des écosystèmes marins.

4.6.1 Présentation de l'application web

L'application est composée de trois principales étapes :

1. **Chargement des données :** L'utilisateur importe les données issues de la cytométrie en flux d'imagerie, sous forme d'un fichier compressé (.zip), contenant les images.
2. **Lancement de l'analyse :** Après avoir téléchargé les données, l'utilisateur déclenche le processus de détection et de classification automatisées des microalgues, permettant au système de traiter les informations importées.
3. **Affichage des résultats :** Les résultats sont présentés sous forme d'images annotées et d'un rapport détaillé. Ce rapport inclut le nombre total de microalgues détectées, le nombre et le pourcentage de *Karenia selliformis*, ainsi que le nombre total des autres microalgues.

4.6.2 Aspects techniques

L'application Web interactive que nous avons développée repose sur une architecture composée de deux éléments clés : Flask pour le backend et Streamlit pour le frontend. Cette combinaison technologique permet de réaliser une analyse automatisée des données issues de la cytométrie en flux d'imagerie en temps réel, tout en répondant aux besoins des biologistes.

4.6.2.1 Backend : API Flask pour la détection et la classification

Le backend est construit avec Flask, un framework Python conçu pour gérer les requêtes HTTP et les interactions avec les utilisateurs. Il est configuré pour recevoir des fichiers ZIP contenant les images des microalgues.

Voici les principales étapes de traitement effectuées dans le backend :

Extraction des images : Une fois le fichiers ZIP reçus, les images sont extraites.

Analyse des images : Deux modèles d'apprentissage profond sont utilisés :

- **YOLOv8** pour la détection des microalgues.
- **ResNet-50** pour la classification des microalgues en "Karenia" ou "Autres"

Une fois l'analyse terminée, le backend retourne les résultats sous forme de JSON au frontend.

Les données envoyées comprennent :

- Les images annotées avec les microalgues détectées.
- Les microalgues extraits avec leur classification respective.

L'API Flask est accessible via l'endpoint /predict, qui reçoit les fichiers et renvoie les résultats sous forme de données JSON.

Voici un extrait montrant la gestion de la requête :

```
@app.route('/predict', methods=['POST'])
def predict():
    if 'file' not in request.files:
        return jsonify({"error": "No file uploaded"}), 400

    try:
        file = request.files['file']
        print(f"Fichier reçu: {file.filename}")

        zip_file = zipfile.ZipFile(io.BytesIO(file.read()))
        response_data = []

        #Détection des microalgues avec YOLOv8
        #Classification des microalgues avec ResNet-50

        return jsonify(response_data), 200

    # Démarrer l'application Flask
if __name__ == '__main__':
    app.run(host="0.0.0.0", port=5000)
```

FIGURE 4.15 – API Flask

4.6.2.2 Frontend : Automatisation des calculs et gestion visuelle avec Streamlit

Le frontend de l'application est développé avec Streamlit, une bibliothèque Python permettant de créer des interfaces web interactives. Le rôle de Streamlit dans cette application est crucial pour la gestion des résultats et leur visualisation.

Les principales fonctionnalités du frontend incluent :

- **Affichage des images annotées** : Les images traitées par les modèles d'apprentissage sont affichées avec les microalgues détectées.
- **Calcul automatisé des statistiques** : Streamlit calcule automatiquement le pourcentage du *Karenia Selliformis* par rapport au nombre total d'images.
- **Rapport global** : un rapport récapitulatif est généré, comprenant le nombre total de microalgues détectées, le nombre et le pourcentage de *Karenia selliformis*, ainsi que le nombre total des autres microalgues.

En plus de ces fonctions, Streamlit offre une navigation fluide entre les différentes images analysées, permettant aux utilisateurs de consulter les résultats image par image.

Streamlit, couplé au backend Flask, permet d'intégrer puissance de traitement et facilité d'utilisation, garantissant ainsi une expérience fluide et complète pour l'utilisateur final.

4.6.3 Interface utilisateur et fonctionnalités

L'application facilite l'interaction entre l'utilisateur et le système grâce à Flask pour le backend et Streamlit pour le frontend. Flask gère les requêtes des utilisateurs, traite les images et applique des modèles d'intelligence artificielle pour détecter et classer les microalgues. Streamlit, pour le frontend, permet aux utilisateurs de charger des images, d'envoyer des requêtes et de visualiser les résultats en temps réel.

Ci-dessous, nous présentons les différentes interfaces de l'application et les fonctionnalités clés, accompagnées de figures pour illustrer chaque étape.

4.6.3.1 Interface de chargement et de détection des images

Sur la première interface, l'utilisateur a la possibilité de télécharger un dossier contenant les images des microalgues. Une fois le dossier sélectionné, il suffit de cliquer sur le bouton 'Lancer la détection' pour envoyer les images au backend, où elles seront traitées par les modèles d'intelligence artificielle pour la détection et la classification des microalgues, comme illustré dans la figure 4.16, montrant l'interface de chargement de données.




FIGURE 4.16 – Interface de chargement des données

La figure 4.16 illustre l'interface où l'utilisateur sélectionne un dossier ZIP contenant les images des microalgues, puis clique sur le bouton pour lancer la détection et le traitement des données.

4.6.3.2 Affichage des résultats de la détection et de la classification

Après le traitement de chaque image, l'interface affiche les résultats de la détection. Les glomérules identifiés sont entourés de rectangles rouges pour ceux classifiés comme *Karenia selliformis* et de rectangles verts pour ceux classifiés comme autres microalgues.




FIGURE 4.17 – Résultats de la détection pour les autres microalgues





FIGURE 4.18 – Résultats de la détection pour le *Karenia Selliformis*

Les figures 4.17 et 4.18 illustrent le résultat de la détection : la figure 4.17 met en évidence deux autres microalgues entourées en vert, tandis que la figure 4.18 montre *Karenia Selliformis*, entourée en rouge.


Affichage des microalgues extraites

Sous l'image annotée, les microalgues détectées sont extraites et affichées individuellement. Chaque microalgue est associée à sa classification (*Karenia* ou autres), permettant à l'utilisateur de visualiser distinctement chaque élément identifié.

Microalgues Extraits



Classe: Autres



Classe: Autres

FIGURE 4.19 – Extraction des autres microalgues

Microalgues Extraits



Classe: Karenia

FIGURE 4.20 – Extraction du *Karenia Selliformis*

Les figures 4.19 et 4.20 présentent les microalgues extraites et affichées sous l'image annotée traitée par le système. Chaque microalga détectée est associée à sa classification, distinguant clairement les *Karenia Selliformis* des autres microalgues. Cette représentation permet à l'utilisateur de consulter individuellement les microalgues identifiées, offrant une vue détaillée et organisée qui simplifie l'interprétation des résultats et facilite une analyse approfondie.

Génération du rapport global

Une fois que toutes les images ont été analysées, l'application permet de générer un rapport global grâce à un bouton dédié. Ce rapport fournit un résumé complet des résultats, comprenant :

- Le nombre total d'images traitées.
- Le nombre total de *Karenia Selliformis* identifiées.
- Le pourcentage de *Karenia Selliformis* par rapport au total des microalgues détectées.
- Le nombre total des autres microalgues.
- Le pourcentage des autres microalgues par rapport au total des microalgues détectées.

Rapport global

- Nombre total d'images traitées : 15
- Karenia : 9 (56.25%)
- Autres : 7 (43.75%)

Retour

FIGURE 4.21 – Rapport global

La figure 4.21 illustre un exemple de rapport global généré par l'application pour un patient, présentant le nombre d'images traitées, le nombre total de *Karenia Selliformis* et d'autres microalgues détectées, ainsi que le pourcentage de *Karenia Selliformis* par rapport au total des microalgues, permettant une synthèse claire des résultats de l'analyse.

4.7 Conclusion

Ce chapitre a présenté notre démarche expérimentale, en détaillant les environnements matériels et logiciels utilisés, ainsi que les mesures d'évaluation employées. Nous avons exposé les résultats obtenus avec les modèles YOLOv8 pour la détection et le modèle ResNet-50 pour la classification des microalgues. L'évaluation des résultats a mis en évidence l'impact de la multiplication rapide de *Karenia Selliformis*. En conclusion, ce chapitre a permis d'évaluer l'efficacité de nos méthodes tout en ouvrant des pistes d'exploration pour de futures améliorations. Le développement de l'interface web a constitué une étape essentielle pour rendre ces modèles accessibles et faciles à utiliser, offrant ainsi un outil pour les chercheurs et les biologistes dans la surveillance et l'analyse des microalgues toxiques en temps réel.



Conclusion générale et perspectives

Dans cette étude, nous avons développé un modèle hybride d'intelligence artificielle combinant YOLOv8 pour la détection et ResNet50 pour la classification afin de différencier *Karenia selliformis* des autres microalgues. Le modèle YOLOv8 a montré une performance solide de 94%, indiquant une capacité élevée à localiser les cellules de *Karenia selliformis* dans les images. Cette précision est essentielle pour la surveillance des écosystèmes aquatiques, où la détection précoce de cette microalgue peut prévenir des effets écologiques négatifs liés à son prolifération excessive. En parallèle, pour la classification, nous avons utilisé le modèle ResNet50, que nous avons fine-tuné pour l'adapter spécifiquement à notre tâche. Ce modèle a atteint une performance remarquable en classification, prouvant sa capacité à distinguer efficacement les deux classes, *Karenia selliformis* et les autres microalgues, en se basant sur des caractéristiques visuelles pertinentes extraites des images. Le fine-tuning a permis d'adapter les couches finales de ce modèle préentraîné pour améliorer sa précision sur nos données spécifiques, avec une performance de 93% en classification.

En conclusion, ce projet tente de proposer une solution novatrice pour la détection et la classification de *Karenia selliformis*, en utilisant des approches de pointe en intelligence artificielle et en cytométrie en flux d'imagerie. Grâce à l'optimisation et à l'entraînement de modèles avancés, notamment YOLOv8 et ResNet50, auxquels nous avons appliqué un fine-tuning pour les adapter aux particularités de notre base de données, nous avons démontré la faisabilité et l'efficacité d'une classification précise et rapide pour la surveillance des microalgues. Ce travail tente de montrer que les méthodes de deep learning sont non seulement pertinentes, mais également essentielles pour relever les défis liés à l'identification et au suivi des espèces de microalgues, en particulier les espèces toxiques comme *Karenia selliformis*, qui peuvent avoir des effets considérables sur les écosystèmes aquatiques. Le projet est une ébauche

qui peut ouvrir également plusieurs perspectives intéressantes pour la suite des recherches. D'une part, nous prévoyons de développer un modèle capable de classer l'ensemble des microalgues présentes dans nos échantillons en fonction de leur classe taxonomique. En élargissant le modèle pour qu'il reconnaisse plusieurs types de microalgues au-delà de *Karenia selliformis*, notre objectif est de faciliter une identification rapide et précise d'une diversité de microalgues, incluant celles potentiellement toxiques. Cette extension pourrait contribuer non seulement à une surveillance plus complète des écosystèmes aquatiques, mais aussi à la détection précoce des espèces nuisibles, permettant ainsi de mieux anticiper les risques pour les milieux marins et la santé publique.

Nous envisageons également d'incorporer des fonctionnalités de reconnaissance des microalgues, qui pourraient inclure l'identification de leurs différents stades de développement, tels que les kystes, les spores et les cellules végétatives, ou encore la détection d'anomalies morphologiques ou structurelles. Une telle approche pourrait offrir des informations pertinentes sur le cycle de vie et les éventuels signaux de stress environnementaux, avec des implications écologiques importantes. Par exemple, détecter des formes anormales pourrait indiquer des changements dans les conditions environnementales, ce qui peut être un indicateur de perturbations écologiques. C'est ainsi qu'on peut intervenir pour limiter les dégâts écologiques.

En parallèle, nous envisageons de combiner les images de cytométrie en flux avec des signaux quantitatifs issus de la cytométrie pour enrichir la base d'information, ce qui pourrait améliorer la précision de la classification en intégrant davantage de paramètres morphologiques et de comportements cellulaires. Une telle approche multimodale permettrait au modèle de mieux comprendre les microalgues et d'affiner la détection des espèces toxiques de manière plus fiable.

Enfin, pour optimiser cette recherche, il est judicieux de créer un axe de développement prometteur qui consisterait à étendre notre solution pour prédire les tendances de prolifération de *Karenia selliformis* en intégrant des données temporelles et environnementales dans les modèles prédictifs. En surveillant ces facteurs, nous pourrions anticiper les épisodes de prolifération, ce qui serait particulièrement utile pour la gestion et la protection des écosystèmes. En somme, cette recherche offre d'éventuels outils de surveillance écologique intelligents,

capables de s'adapter et de répondre aux besoins de préservation de l'environnement aquatique tout en contribuant à une meilleure gestion des risques pour la santé publique et la biodiversité.



BIBLIOGRAPHIE

- [1] www.wikipedia.org/wiki/Karenia-selliformis#cite-note-HaywoodSteidinger2004-1
- [2] IWATAKI, Mitsunori, LUM, Wai Mun, KUWATA, Koyo, et al. Morphological variation and phylogeny of *Karenia selliformis* (Gymnodiniales, Dinophyceae) in an intensive cold-water algal bloom in eastern Hokkaido, Japan. *Harmful Algae*, 2022, vol. 114, p. 102204.
- [3] Feki-Sahnoun, W., Njah, H., Hamza, A. et al. Using a naive Bayes classifier to explore the factors driving the harmful dinoflagellate *Karenia selliformis* blooms in a southeastern Mediterranean lagoon. *Ocean Dynamics* 70, 897–911 (2020).
- [4] www.kapitalis.com/tunisie/2019/11/18/tunisie-des-algues-marines-toxiques-font-virer-la-couleur-de-la-mer-au-rouge-dans-plusieurs-regions/
- [5] Thèse de doctorat soutenu en 2014 HABIB, Mr. Ayadi, AMEL, Maatamri Medhioub, et RODOLPHE, Lemée. Moufida ABDENNADHER
- [6] KESKES, Fatma Abdmouleh, AYADI, Najla, ATOUI, Abdelfattah, et al. Dinoflagellates encystment with emphasis on blooms in Boughrara Lagoon (South-Western Mediterranean) : Combined effects of trace metal concentration and environmental context. *Estuarine, Coastal and Shelf Science*, 2020, vol. 237, p. 106648.
- [7] Barsanti, L., Birindelli, L., Gualtieri, P. (2021). Water monitoring by means of digital microscopy identification and classification of microalgae. *Environmental Science : Processes et Impacts*, 23(10), 1443-1457.
- [8] ZAFRANI, L. et MONNERET, G. Comprendre la cytométrie en flux. *Médecine Intensive Réanimation*, 2017, vol. 26, no 6, p. 517.
- [9] https://fr.wikipedia.org/wiki/Cytométrie_en_flux
- [10] https://fr.wikipedia.org/wiki/Intelligence_artificielle

- [11] https://fr.wikipedia.org/wiki/Apprentissage_automatique
- [12] https://fr.wikipedia.org/wiki/Apprentissage_profond
- [13] https://fr.wikipedia.org/wiki/RC3A9seau_de_neurones_artificiels
- [14] <https://medium.com/@freedomcode12/unveiling-the-power-of-convolutional-neural-networks-cnns-1754fd7bd2de>
- [15] <https://www.semanticscholar.org/paper/Data-Driven-System-Identification-of-6-DoF-Ship-in-Silva-Maki/dfeb85a36556d0c3f31abaf54b8106640fcbfa42/figure/4>
- [16] Sonmez, M. E., Gumus, N. E., Eczacioglu, N., Develi, E. E., Yücel, K., & Yildiz, H. B. (2024). Enhancing microalgae classification accuracy in marine ecosystems through convolutional neural networks and support vector machines. *Marine Pollution Bulletin*, 205, 116616.
- [17] Chong, J. W. R., Khoo, K. S., Chew, K. W., Ting, H. Y., Iwamoto, K., Ruan, R., ... & Show, P. L. (2024). Artificial intelligence-driven microalgae autotrophic batch cultivation : A comparative study of machine and deep learning-based image classification models. *Algal Research*, 79, 103400
- [18] Sun, Y., Tian, Y., Zhang, Y., Yu, M., Su, X., Wang, Q., ... & Ren, L. (2024). A double-branch convolutional neural network model for species identification based on multi-modal data. *Spectrochimica Acta Part A : Molecular and Biomolecular Spectroscopy*, 318, 124454.
- [19] Pant, G., Yadav, D. P., & Gaur, A. (2020). ResNeXt convolution neural network topology-based deep learning model for identification and classification of *Pediastrum*. *Algal research*, 48, 101932.
- [20] Sonmez, M. E., Altinsoy, B., Ozturk, B. Y., Gumus, N. E., & Eczacioglu, N. (2023). Deep learning-based classification of microalgae using light and scanning electron microscopy images. *Micron*, 172, 103506.
- [21] ZHENG, Jiahao, COLE, Tim, ZHANG, Yuxin, et al. An automated and intelligent microfluidic platform for microalgae detection and monitoring. *Lab on a Chip*, 2024, vol. 24, no 2, p. 244-253.

- [22] YANG, Hao, LANG, Kaiqi, et WANG, Xiaoping. Identify and segment microalgae in complex backgrounds with improved YOLO. *Algal Research*, 2024, vol. 82, p. 103651.
- [23] DUAN, Ziqiang, XIE, Ting, WANG, Lucai, et al. Microalgae detection based on improved YOLOv5. *IET Image Processing*, 2024.
- [24] Chen, Y., Liu, Y., Wang, J., Zhang, Y., & Bai, Y. (2023). Accurate detection of microalgae in ship ballast water : An innovative computer vision strategy. *Ecological Informatics*, 78, 102311.
- [25] Cao M., Wang J., Chen Y., Wang Y. (2021). Detection of microalgae objects based on the improved YOLOv3 model. *Environ. Science : Processes Impacts* 23, 1516–1530. doi : 10.1039/D1EM00159K
- [26] YAN, Huchao, PENG, Xinggan, CHEN, Cheng, et al. YOLOx model-based object detection for microalgal bioprocess. *Algal Research*, 2023, vol. 74, p. 103178.
- [27] ZHOU, Shizheng, JIANG, Juntao, HONG, Xiaohan, et al. Vision meets algae : A novel way for microalgae recognition and health monitor. *Frontiers in Marine Science*, 2023, vol. 10, p. 1105545.
- [28] ABDULLAH, ALI, Sikandar, KHAN, Ziaullah, et al. Computer vision based deep learning approach for the detection and classification of algae species using microscopic images. *Water*, 2022, vol. 14, no 14, p. 2219.
- [29] PARK, Jungsu, BAEK, Jiwon, KIM, Jongrack, et al. Deep learning-based algal detection model development considering field application. *Water*, 2022, vol. 14, no 8, p. 1275.
- [30] PARK, Jungsu, BAEK, Jiwon, YOU, Kwangtae, et al. Microalgae detection using a deep learning object detection algorithm, YOLOv3. *Journal of Korean Society on Water Environment*, 2021, vol. 37, no 4, p. 275-285.
- [31] LIU, Dan, WANG, Pengqi, CHENG, Yuan, et al. An improved algae-YOLO model based on deep learning for object detection of ocean microalgae considering aquacultural lightweight deployment. *Frontiers in Marine Science*, 2022, vol. 9, p. 1070638.
- [32] ZHANG, Ziyao, YANG, Haoxiang, ESHRAGHIAN, Jason K., et al. Cell detection with convolutional spiking neural network for neuromorphic cytometry. *APL Machine Learning*, 2024, vol. 2, no 2.

- [33] LUO, Shaobo, NGUYEN, Kim Truc, NGUYEN, Binh TT, et al. Deep learning-enabled imaging flow cytometry for high-speed *Cryptosporidium* and *Giardia* detection. *Cytometry Part A*, 2021, vol. 99, no 11, p. 1123-1133.
- [34] Luo, S., Shi, Y., Chin, L. K., Hutchinson, P. E., Zhang, Y., Chierchia, G., ... & Liu, A. Q. (2021). Machine-learning-assisted intelligent imaging flow cytometry : A review. *Advanced Intelligent Systems*, 3(11), 2100073.
- [35] Harmon, J., Mikami, H., Kanno, H., Ito, T., & Goda, K. (2020). Accurate classification of microalgae by intelligent frequency-division-multiplexed fluorescence imaging flow cytometry. *Osa Continuum*, 3(3), 430-440.
- [36] KIM, Taehee, PRADHAN, Biswajita, et KI, Jang-Seu. Staining to machine learning : An emerging technology for determination of microalgal cell viability. *Journal of Applied Phycology*, 2024, p. 1-20.
- [37] DU, Ziqiang, LI, Ya, CHEN, Bing, et al. Label-free detection and enumeration of rare circulating tumor cells by bright-field image cytometry and multi-frame image correlation analysis. *Lab on a Chip*, 2022, vol. 22, no 18, p. 3390-3401.
- [38] OTESTEANU, Corin F., UGRINIC, Martina, HOLZNER, Gregor, et al. A weakly supervised deep learning approach for label-free imaging flow-cytometry-based blood diagnostics. *Cell reports methods*, 2021, vol. 1, no 6.
- [39] LI, Yueqin, MAHJOUBFAR, Ata, CHEN, Claire Lifan, et al. Deep cytometry : deep learning with real-time inference in cell sorting and flow cytometry. *Scientific reports*, 2019, vol. 9, no 1, p. 11088.
- [40] <https://medium.com/@vindyalenawala/yolov8-architecture-a-detailed-overview-5e2c371cf82a>
- [41] <https://medium.com/analytics-vidhya/converting-annotations-for-object-detection-using-roboflow-5d0760bd5871>
- [42] <https://ledatascientist.com/google-colab-le-guide-ultime/>
- [43] [https://fr.wikipedia.org/wiki/Python_\(langage\)](https://fr.wikipedia.org/wiki/Python_(langage))
- [44] <https://loud-technology.com/programmation/definitions/tensor-flow/>
- [45] <https://fr.wikipedia.org/wiki/NumPy>

[46] <https://fr.wikipedia.org/wiki/PyTorch>

[47] <https://intelligence-artificielle.com/confusion-matrix-dossier-complet/>

[48] https://www.researchgate.net/figure/oU-calculation-formula-IoU-of-050095-is-considered-TP-detection_fig4_369743374

Détection et classification du Karenia Selliformis par cytométrie

Farah Khemakhem

Résumé :

Ce projet, réalisé dans le cadre de mon mémoire de Master en Sciences de l'Informatique, a pour objectif de développer une solution d'intelligence artificielle pour la détection et la classification de la microalgue Karenia selliformis. L'approche combine le modèle YOLOv8 pour la détection et ResNet50 pour la classification, avec un fine-tuning, permettant de différencier cette microalgue des autres espèces et de mieux surveiller les écosystèmes aquatiques. Ce travail démontre l'efficacité des modèles de deep learning pour suivre et gérer les espèces toxiques de microalgues, contribuant ainsi à une gestion améliorée des impacts écologiques des blooms de Karenia selliformis.

Mots clés : Détection des microalgues, Classification, Karenia Selliformis, Apprentissage profond, fine-Tuning, Cytométrie.

Abstract :

This project, carried out as part of my Master's thesis in Computer Science, aims to develop an artificial intelligence solution for the detection and classification of the microalgae Karenia selliformis. The approach combines the YOLOv8 model for detection and ResNet50 for classification, with fine-tuning, to differentiate this microalgae from other species and improve the monitoring of aquatic ecosystems. This work demonstrates the effectiveness of deep learning models in tracking and managing toxic microalgae species, contributing to better management of the ecological impacts of Karenia selliformis blooms.

Key-words : Microalgae Detection, Classification, Karenia Selliformis, Deep Learning, Fine-Tuning, Cytometry.

تلخيص

يهدف هذا المشروع، الذي تم إنجازه في إطار رسالة الماجستير في علوم الحاسوب، إلى تطوير حل يعتمد على الذكاء الاصطناعي للكشف وتصنيف الطحالب الدقيقة Karenia selliformis. تجمع المقاربة بين نموذج YOLOv8 للكشف وResNet50 للتصنيف، مع استخدام التخصيص الدقيق (fine-tuning)، مما يمكن من التمييز بين هذه الطحالب الدقيقة والأنواع الأخرى، ويعزز من مراقبة الأنظمة البيئية المائية. يُظهر هذا العمل فعالية نماذج التعلم العميق في متابعة وإدارة الأنواع السامة من الطحالب الدقيقة، مما يساهم في تحسين إدارة الآثار البيئية الناتجة عن ازدهار هذه الطحالب الدقيقة السامة.

المفاتيح: كشف الطحالب الدقيقة، التصنيف، Karenia Selliformis، التعلم العميق، التخصيص الدقيق (Fine-Tuning)، قياس التدفق الخلوي.

